

**BỘ CÔNG THƯƠNG**  
**TRƯỜNG ĐẠI HỌC KINH TẾ - KỸ THUẬT CÔNG NGHIỆP**

**KHOÁ LUẬN TỐT NGHIỆP**

**TÊN ĐỀ TÀI KHÓA LUẬN:**  
**XÂY DỰNG MÔ HÌNH NGÔN NGỮ**  
**HỖ TRỢ GIẢI BÀI TẬP XÁC SUẤT**

**Ngành đào tạo: Khoa học Dữ liệu**  
**Mã số ngành: 7460108**

**Sinh viên thực hiện: Lê Đình Tùng**

**Người hướng dẫn khóa luận tốt nghiệp**  
**TS. Trần Thị Hoàng Yến**

**Hà Nội – 2026**

**BỘ CÔNG THƯƠNG**  
**TRƯỜNG ĐẠI HỌC KINH TẾ - KỸ THUẬT CÔNG NGHIỆP**

**KHOÁ LUẬN TỐT NGHIỆP**

**TÊN ĐỀ TÀI KHÓA LUẬN:**  
**XÂY DỰNG MÔ HÌNH NGÔN NGỮ**  
**HỖ TRỢ GIẢI BÀI TẬP XÁC SUẤT**

**Ngành đào tạo: Khoa học Dữ liệu**  
**Mã số ngành: 7460108**

**Sinh viên thực hiện: Lê Đình Tùng**

**Người hướng dẫn khóa luận tốt nghiệp**  
**TS. Trần Thị Hoàng Yến**

**Hà Nội – 2026**

## LỜI CAM ĐOAN

Em là sinh viên thực hiện đề tài: “Xây dựng mô hình ngôn ngữ hỗ trợ giải bài tập xác suất”.

Em xin cam đoan:

Khóa luận này là công trình nghiên cứu độc lập của em, được thực hiện dưới sự hướng dẫn khoa học trực tiếp của Giảng viên hướng dẫn.

Toàn bộ dữ liệu huấn luyện, mã nguồn, cấu hình siêu tham số và kết quả thực nghiệm trình bày trong khóa luận là hoàn toàn trung thực, do em tự thiết lập và thực thi. Các kết quả này chưa từng được công bố hay sử dụng để bảo vệ bất kỳ học vị nào tại cơ sở đào tạo khác.

Mọi thông tin tham khảo và trích dẫn từ tài liệu, bài báo khoa học hay mã nguồn mở đều được ghi rõ nguồn gốc và liệt kê đầy đủ trong danh mục Tài liệu tham khảo, tuân thủ nghiêm túc các quy định về sở hữu trí tuệ và đạo đức nghiên cứu khoa học.

Em xin chịu hoàn toàn trách nhiệm trước Hội đồng đánh giá, Khoa Khoa học Ứng dụng và Trường Đại học Kinh tế Kỹ thuật Công nghiệp về tính trung thực của lời cam đoan này.

*Hà Nội, ngày ... tháng ... năm 2026*

**Sinh viên thực hiện**

*(Ký và ghi rõ họ tên)*

**Lê Đình Tùng**

## LỜI CẢM ƠN

Trong suốt quá trình học tập, nghiên cứu và hoàn thành khóa luận tốt nghiệp này, em đã nhận được sự quan tâm, giúp đỡ và động viên quý báu từ thầy cô, gia đình và bạn bè.

Trước tiên, em xin gửi lời cảm ơn sâu sắc nhất đến TS.Trần Thị Hoàng Yến, người đã trực tiếp giao đề tài, tận tình định hướng khoa học và truyền đạt những kiến thức, kinh nghiệm quý báu trong suốt quá trình thực hiện nghiên cứu.

Em xin trân trọng cảm ơn Ban Giám hiệu Trường Đại học Kinh tế – Kỹ thuật Công nghiệp cùng toàn thể quý thầy cô Khoa Khoa học Ứng dụng đã tận tâm giảng dạy, tạo điều kiện học tập thuận lợi và trang bị cho em nền tảng tri thức vững chắc trong suốt những năm trên giảng đường.

Mặc dù đã nỗ lực hết mình, song do giới hạn về thời gian và kinh nghiệm thực tiễn, khóa luận chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được những nhận xét, góp ý của Hội đồng đánh giá và quý thầy cô để đề tài được hoàn thiện hơn.

Cuối cùng, em xin bày tỏ lòng biết ơn chân thành đến gia đình và những người bạn đã luôn đồng hành, động viên và tạo mọi điều kiện thuận lợi để em hoàn thành khóa luận này.

*Hà Nội, ngày ... tháng ... năm 2026*

**Sinh viên thực hiện**

*(Ký và ghi rõ họ tên)*

**Lê Đình Tùng**

## MỤC LỤC

|                                                                         |      |
|-------------------------------------------------------------------------|------|
| LỜI CAM ĐOAN.....                                                       | ii   |
| LỜI CẢM ƠN .....                                                        | iii  |
| CÁC TỪ VIẾT TẮT.....                                                    | vi   |
| DANH MỤC CÁC BẢNG .....                                                 | viii |
| DANH MỤC CÁC HÌNH.....                                                  | ix   |
| PHẦN MỞ ĐẦU.....                                                        | 1    |
| CHƯƠNG 1: TỔNG QUAN NGHIÊN CỨU VÀ NỀN TẢNG LÝ THUYẾT .....              | 8    |
| 1.1. PHÂN TÍCH BÀI TOÁN ỨNG DỤNG .....                                  | 8    |
| 1.2. NỀN TẢNG LÝ THUYẾT.....                                            | 9    |
| 1.2.1. Tổng quan về mô hình ngôn ngữ lớn và Kiến trúc Transformer ..... | 9    |
| 1.2.2. Kiến trúc và đặc điểm của các mô hình nghiên cứu .....           | 13   |
| 1.2.3. Kỹ thuật Chain-of-Thought Prompting .....                        | 16   |
| 1.2.4. Tinh chỉnh tham số hiệu quả với LoRA và QLoRA .....              | 18   |
| 1.2.5. Phương pháp LLM-as-a-Judge .....                                 | 20   |
| 1.2.6. Tổng quan các dạng bài toán Xác suất Thống kê cốt lõi .....      | 23   |
| 1.3. TỔNG QUAN VĂN LIỆU VÀ CÔNG TRÌNH LIÊN QUAN.....                    | 25   |
| 1.3.1. Nghiên cứu quốc tế về năng lực giải toán của LLM.....            | 25   |
| 1.3.2. Nghiên cứu tại Việt Nam.....                                     | 26   |
| 1.3.3. Khoảng trống nghiên cứu .....                                    | 26   |
| CHƯƠNG 2: THIẾT KẾ GIẢI PHÁP VÀ XÂY DỰNG MÔ HÌNH.....                   | 28   |
| 2.1. PHÂN TÍCH DỮ LIỆU VÀ TIỀN XỬ LÝ .....                              | 28   |
| 2.1.1. Thu thập và xây dựng tập dữ liệu bài tập XSTK.....               | 28   |
| 2.1.2. Làm sạch dữ liệu và thiết kế cấu trúc Prompt.....                | 30   |
| 2.2. THIẾT KẾ KIẾN TRÚC MÔ HÌNH .....                                   | 32   |

|                                                              |    |
|--------------------------------------------------------------|----|
| 2.2.1. Lựa chọn phiên bản cụ thể của Gemma và Qwen .....     | 32 |
| 2.2.2. Thiết lập siêu tham số cho cấu hình QLoRA.....        | 34 |
| 2.3. LẬP KẾ HOẠCH TRIỂN KHAI .....                           | 37 |
| 2.3.1. Lựa chọn công cụ và môi trường huấn luyện.....        | 37 |
| 2.3.2. Quy trình thực hiện.....                              | 38 |
| CHƯƠNG 3: TRIỂN KHAI KỸ THUẬT VÀ PHÂN TÍCH THỰC NGHIỆM ..... | 41 |
| 3.1. TRIỂN KHAI KỸ THUẬT .....                               | 41 |
| 3.1.1. Cấu hình môi trường và nền tảng tính toán .....       | 41 |
| 3.1.2. Cấu hình siêu tham số huấn luyện.....                 | 41 |
| 3.1.3. Quá trình huấn luyện .....                            | 42 |
| 3.2. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH .....                  | 43 |
| 3.2.1. Đánh giá quá trình huấn luyện (Training Loss).....    | 43 |
| 3.2.2. Đánh giá khả năng giải toán trên tập Test .....       | 44 |
| 3.2.3. Đánh giá chất lượng suy luận bằng LLM-as-a-Judge..... | 46 |
| 3.3. PHÂN TÍCH SO SÁNH HIỆU SUẤT.....                        | 47 |
| 3.3.1. So sánh độ chính xác và chất lượng lời giải.....      | 47 |
| 3.3.2. So sánh tài nguyên tính toán.....                     | 48 |
| CHƯƠNG 4: ĐÁNH GIÁ CHUYÊN SÂU VÀ CHIẾN LƯỢC CẢI TIẾN.....    | 50 |
| 4.1. ĐÁNH GIÁ TOÀN DIỆN KẾT QUẢ .....                        | 50 |
| 4.1.1. Ưu điểm của mô hình .....                             | 50 |
| 4.1.2. Phân tích hạn chế và hiện tượng ảo giác.....          | 50 |
| 4.2. ĐỀ XUẤT CHIẾN LƯỢC CẢI TIẾN .....                       | 51 |
| 4.3. ĐẠO ĐỨC VÀ PHÁP LÝ TRONG ỨNG DỤNG AI HỌC THUẬT .....    | 51 |
| KẾT LUẬN.....                                                | 53 |
| TÀI LIỆU THAM KHẢO.....                                      | 55 |

CÁC TỪ VIẾT TẮT

| Từ viết tắt | Cụm từ đầy đủ                                                       |
|-------------|---------------------------------------------------------------------|
| AI          | Trí tuệ nhân tạo (Artificial Intelligence)                          |
| LLM         | Mô hình ngôn ngữ lớn (Large Language Model)                         |
| NLP         | Xử lý ngôn ngữ tự nhiên (Natural Language Processing)               |
| XSTK        | Xác suất Thống kê                                                   |
| SFT         | Tinh chỉnh có giám sát (Supervised Fine-Tuning)                     |
| PEFT        | Tinh chỉnh tham số hiệu quả (Parameter-Efficient Fine-Tuning)       |
| LoRA        | Thích nghi hạng thấp (Low-Rank Adaptation)                          |
| QLoRA       | Tinh chỉnh lượng tử hóa hạng thấp (Quantized Low-Rank Adaptation)   |
| CoT         | Chuỗi suy luận từng bước (Chain-of-Thought)                         |
| RAG         | Sinh có tăng cường truy xuất (Retrieval-Augmented Generation)       |
| DPO         | Tối ưu hóa theo sở thích trực tiếp (Direct Preference Optimization) |
| SCoT        | Chuỗi suy luận có cấu trúc (Structured Chain-of-Thought)            |
| EdTech      | Công nghệ giáo dục (Educational Technology)                         |
| VRAM        | Bộ nhớ đồ họa (Video Random Access Memory)                          |
| GPU         | Bộ xử lý đồ họa (Graphics Processing Unit)                          |

|     |                                                                  |
|-----|------------------------------------------------------------------|
| API | Giao diện lập trình ứng dụng (Application Programming Interface) |
| LMS | Hệ thống quản lý học tập (Learning Management System)            |
| MQA | Cơ chế chú ý đa truy vấn (Multi-Query Attention)                 |
| GQA | Cơ chế chú ý theo nhóm truy vấn (Grouped-Query Attention)        |
| FFN | Mạng truyền thẳng (Feed-Forward Network)                         |



## DANH MỤC CÁC BẢNG

|                                                                                              |    |
|----------------------------------------------------------------------------------------------|----|
| Bảng 2. 1. Phân bổ dữ liệu theo nhóm chủ đề .....                                            | 29 |
| Bảng 2. 2. Cấu hình siêu tham số lượng tử hóa BitsAndBytes.....                              | 34 |
| Bảng 2. 3. Cấu hình siêu tham số LoRA Adapter.....                                           | 35 |
| Bảng 2. 4. Cấu hình siêu tham số huấn luyện SFTTrainer .....                                 | 35 |
| Bảng 2. 5. Hệ sinh thái thư viện sử dụng trong nghiên cứu.....                               | 38 |
| Bảng 3. 1. Siêu tham số huấn luyện áp dụng cho hai mô hình.....                              | 41 |
| Bảng 3. 2. Tỷ lệ chính xác (%) theo nhóm chủ đề – so sánh mô hình gốc và sau tinh chỉnh..... | 45 |
| Bảng 3. 3. Điểm đánh giá LLM Judge theo từng nhóm chủ đề.....                                | 46 |
| Bảng 3. 4. So sánh tài nguyên tính toán giữa hai mô hình .....                               | 49 |

## DANH MỤC CÁC HÌNH

|                                                                    |    |
|--------------------------------------------------------------------|----|
| Hình 1. 1. Kiến trúc tổng thể của mô hình Transformer[6] .....     | 9  |
| Hình 1. 2. Tổng quan kiến trúc mô hình Gemma-7B-it.....            | 13 |
| Hình 1. 3. Tổng quan kiến trúc mô hình Qwen2.5-Math.....           | 14 |
| Hình 1. 4. Minh họa kỹ thuật Chain-of-Thought Prompting.....       | 16 |
| Hình 1. 5. Mô hình hóa kỹ thuật tinh chỉnh LoRA và QLoRA [7] ..... | 19 |
| Hình 1. 6. Pipeline đánh giá tự động LLM as a Judge.....           | 23 |
| Hình 2. 1. Minh họa bộ dữ liệu sau khi tiền xử lý.....             | 28 |
| Hình 2. 2. Quy trình thu thập và xây dựng tập dữ liệu XSTK.....    | 30 |
| Hình 2. 3. Quy trình làm sạch và chuẩn hóa dữ liệu.....            | 31 |
| Hình 3. 1. Qwen 2.5 Math Training loss.....                        | 43 |
| Hình 3. 2. Gemma 7b Training loss.....                             | 43 |

## PHẦN MỞ ĐẦU

### 1. Lý do chọn đề tài

Sự phát triển vượt bậc của Trí tuệ Nhân tạo (AI), đặc biệt là sự bùng nổ của các Mô hình ngôn ngữ lớn (Large Language Models – LLM), đã tạo ra những bước ngoặt mang tính cách mạng trong lĩnh vực công nghệ giáo dục (EdTech), làm thay đổi cơ bản cách tiếp cận tri thức của người học. Mặc dù các LLM hiện đại đã chứng minh được năng lực xuất sắc trong nhiều tác vụ xử lý ngôn ngữ tự nhiên như tóm tắt, dịch thuật hay hỏi đáp thông thường, việc ứng dụng chúng vào các miền tri thức chuyên sâu – nơi đòi hỏi tư duy logic chặt chẽ, khả năng trừu tượng hóa và suy luận toán học nhiều bước như học phần Xác suất Thống kê (XSTK) bậc đại học – vẫn đối mặt với nhiều rào cản kỹ thuật đáng kể. Điển hình nhất là hiện tượng “ảo giác” (hallucination), khi mô hình sinh ra các bước giải thiếu cơ sở toán học, lập luận đứt gãy hoặc vi phạm các quy tắc số học, dù vẫn phong trình bày rất tự tin.

Các mô hình thương mại mã nguồn đóng hàng đầu như GPT-4 hay Claude có thể xử lý tương đối tốt các dạng bài toán này. Tuy nhiên, việc phụ thuộc hoàn toàn vào các API độc quyền không chỉ tạo ra gánh nặng chi phí vận hành và nguy cơ rò rỉ dữ liệu học thuật mà còn đặt người dùng vào trạng thái “hộp đen” (black-box), không thể kiểm soát hay can thiệp vào quá trình suy luận bên trong của mô hình. Trong khi đó, hệ sinh thái mã nguồn mở đang phát triển mạnh mẽ, nhưng các bộ dữ liệu huấn luyện toán học chất lượng cao vẫn chủ yếu được thiết kế cho tiếng Anh.

Trước bối cảnh đó, việc nghiên cứu tinh chỉnh (fine-tune) các mô hình mã nguồn mở tiên tiến để chuyên biệt hóa cho bài toán Xác suất Thống kê bằng tiếng Việt là một nhu cầu mang tính cấp thiết. Bằng cách chuẩn hóa dữ liệu và ép mô hình suy luận theo tư duy từng bước (Chain-of-Thought), nghiên cứu không chỉ nhằm tạo ra một trợ lý học tập minh bạch, chính xác cho sinh viên mà còn góp phần khẳng định năng lực tự chủ công nghệ AI trong giáo dục đại học tại Việt Nam. Xuất phát từ những động lực khoa học và thực tiễn đó, đề tài ‘Nghiên cứu ứng dụng và tinh chỉnh Mô hình ngôn ngữ lớn (LLM) trong việc tự động hóa giải bài tập Xác suất – Thống kê bằng tiếng Việt’ đã được lựa chọn làm khóa luận tốt nghiệp.

### 2. Mục tiêu nghiên cứu

Đề tài hướng tới bốn mục tiêu cụ thể sau:

- **Xây dựng bộ dữ liệu (Dataset Construction):** Mục tiêu đầu tiên của đề tài là xây dựng một bộ dữ liệu tiếng Việt chuyên biệt cho học phần Xác suất – Thống kê ở bậc đại học. Quá trình này bao gồm các bước thu thập bài toán từ nguồn học liệu phù hợp, số hóa nội dung, làm sạch dữ liệu và chuẩn hóa định dạng trình bày. Trong bộ dữ liệu, đề bài được tổ chức theo cấu trúc rõ ràng, trong đó các dữ kiện toán học được biểu diễn bằng LaTeX nhằm tăng tính nhất quán và hỗ trợ mô hình nhận diện tốt hơn các ký hiệu, công thức và biểu thức toán học. Bên cạnh đó, lời giải cũng được biên soạn theo từng bước, giúp dữ liệu không chỉ phục vụ cho việc học đáp án cuối mà còn hỗ trợ mô hình học được quá trình suy luận.

- **Tinh chỉnh mô hình (Model Fine-tuning):** Mục tiêu thứ hai là áp dụng kỹ thuật tinh chỉnh tham số hiệu quả (PEFT), cụ thể là QLoRA, để huấn luyện có giám sát (Supervised Fine-Tuning – SFT) trên các mô hình ngôn ngữ lớn mã nguồn mở. Trong nghiên cứu này, hai mô hình được lựa chọn là Gemma-7B-it và Qwen2.5-Math. Việc tinh chỉnh được thực hiện trên cùng một bộ dữ liệu Xác suất – Thống kê bằng tiếng Việt, với kỳ vọng giúp mô hình thích nghi tốt hơn với ngữ cảnh toán học tiếng Việt, đồng thời hình thành khả năng sinh lời giải theo cấu trúc từng bước thay vì chỉ đưa ra đáp án ngắn gọn. Thông qua đó, đề tài hướng tới việc nâng cao cả độ chính xác của kết quả lẫn tính rõ ràng trong quá trình trình bày lời giải.

- **Xây dựng khung đánh giá (Evaluation Framework):** Mục tiêu thứ ba là thiết lập một quy trình đánh giá tự động tương đối khách quan để đo lường chất lượng đầu ra của mô hình. Thay vì chỉ sử dụng các độ đo truyền thống như BLEU hay ROUGE, vốn chủ yếu dựa trên mức độ trùng lặp bề mặt giữa văn bản sinh ra và văn bản tham chiếu, đề tài lựa chọn kết hợp hai hướng đánh giá. Thứ nhất là các chỉ số khớp chính xác (Hard Metrics), dùng để kiểm tra mức độ đúng của đáp án cuối. Thứ hai là phương pháp LLM-as-a-Judge, trong đó một mô hình ngôn ngữ khác được sử dụng để đánh giá sâu hơn về tính logic của lời giải, độ chính xác trong tính toán và mức độ hợp lý của chuỗi suy luận. Cách tiếp cận này giúp việc đánh giá đầu ra của mô hình toàn diện hơn, đặc biệt phù hợp với bài toán giải toán tự luận.

- **Phân tích và đối sánh (Comparative Analysis):** Mục tiêu cuối cùng của đề tài là tiến hành đo lường và phân tích hiệu năng của hai mô hình Gemma-7B-it và Qwen2.5-Math sau quá trình tinh chỉnh. Việc so sánh không chỉ dừng lại ở tỷ lệ trả lời đúng, mà còn mở rộng sang các khía cạnh như chất lượng lập

luận, độ chính xác toán học của từng bước giải và khả năng triển khai trên phần cứng phổ thông. Thông qua quá trình đối sánh này, đề tài mong muốn làm rõ điểm mạnh và điểm hạn chế của từng mô hình khi áp dụng cho bài toán Xác suất – Thống kê bằng tiếng Việt, từ đó đưa ra nhận định phù hợp về hướng lựa chọn mô hình trong các bối cảnh triển khai khác nhau.

### **3. Đối tượng và phạm vi nghiên cứu**

#### **Đối tượng nghiên cứu**

Đề tài tập trung nghiên cứu ba nhóm đối tượng chính: (1) các phương pháp xử lý dữ liệu toán học tiếng Việt và kỹ thuật thiết kế câu lệnh (Prompt Engineering); (2) đặc điểm kiến trúc và cơ chế tinh chỉnh trọng số của hai dòng mô hình ngôn ngữ lớn mã nguồn mở tiêu biểu:

- Gemma-7B-it: Mô hình ngôn ngữ mở do Google DeepMind phát triển, nổi bật với khả năng tối ưu hóa tài nguyên phần cứng và xử lý ngôn ngữ đa dạng, đóng vai trò đại diện cho nhóm mô hình tổng quát trong việc xử lý đề bài tiếng Việt.

- Qwen2.5-Math: Mô hình chuyên biệt được tiền huấn luyện sâu cho lĩnh vực toán học, sở hữu khả năng nhận diện ký hiệu LaTeX và thiết lập chuỗi suy luận logic vượt trội.

Nhóm đối tượng thứ ba bao gồm kỹ thuật lượng tử hóa và tinh chỉnh thích nghi hạng thấp (QLoRA) cùng hệ thống đánh giá mô hình ngôn ngữ lớn tự động (LLM Evaluation Pipeline).

#### **Phạm vi nghiên cứu**

Về mặt dữ liệu: Nghiên cứu giới hạn trong các dạng bài toán cốt lõi thuộc học phần Xác suất Thống kê bậc đại học bằng tiếng Việt, bao gồm: xác suất cổ điển và định lý Bayes; biến ngẫu nhiên và quy luật phân phối; thống kê suy diễn; phân tích tương quan và hồi quy.

Về mặt kỹ thuật: Quá trình tinh chỉnh giới hạn ở các mô hình có quy mô tham số bậc trung ( 7 tỷ tham số) nhằm phù hợp với giới hạn GRAM của GPU phổ thông hiện nay.

### **4. Phương pháp tiếp cận**

Đề tài tiếp cận bài toán thông qua một quy trình kỹ thuật tương đối khép kín và có tính hệ thống, bao quát toàn bộ các bước từ xây dựng dữ liệu, tinh chỉnh mô hình cho đến đánh giá kết quả đầu ra. Cách tiếp cận này được lựa

chọn nhằm bảo đảm rằng mỗi giai đoạn đều có mối liên hệ chặt chẽ với nhau: dữ liệu được thiết kế để phục vụ trực tiếp cho quá trình huấn luyện, quá trình huấn luyện được tối ưu theo điều kiện phần cứng thực tế, và hệ thống đánh giá được xây dựng để phản ánh đúng đặc thù của bài toán giải toán tự luận.

- **Xây dựng và chuẩn hóa dữ liệu (Data Engineering):** Đề tài bắt đầu từ việc thu thập dữ liệu thô từ giáo trình, bài tập mẫu và đề thi thực tế thuộc học phần Xác suất – Thống kê. Trên cơ sở đó, dữ liệu được số hóa, làm sạch và chuẩn hóa thành cấu trúc thống nhất để phục vụ cho huấn luyện mô hình. Điểm quan trọng trong bước này là lời giải không được lưu dưới dạng văn bản tự do, mà được tổ chức theo chuỗi các bước phân rã rõ ràng, chẳng hạn như phân tích giả thiết, xác định công thức phù hợp, thay số và rút ra kết luận cuối cùng. Đồng thời, các công thức và biểu thức toán học được mã hóa theo chuẩn LaTeX nhằm tăng tính nhất quán và giúp mô hình nhận diện tốt hơn các ký hiệu toán học. Cách tổ chức dữ liệu như vậy không chỉ giúp mô hình học được đáp án cuối, mà còn hướng mô hình học cả tiến trình suy luận từng bước, phù hợp với đặc thù của bài toán Xác suất – Thống kê.

- **Tinh chỉnh mô hình (Fine-tuning):** Sau khi bộ dữ liệu được chuẩn hóa, đề tài triển khai quá trình tinh chỉnh hai mô hình ngôn ngữ lớn mã nguồn mở là Gemma-7B-it và Qwen2.5-Math bằng kỹ thuật QLoRA. Trong cách tiếp cận này, trọng số của mô hình nền được lượng tử hóa xuống chuẩn 4-bit NF4 để giảm yêu cầu bộ nhớ, trong khi quá trình huấn luyện chỉ cập nhật các ma trận thích nghi hạng thấp (adapter) được chèn vào một số thành phần của mô hình, chủ yếu là các lớp Attention. Việc áp dụng QLoRA cho phép thực hiện fine-tuning trên GPU phổ thông như NVIDIA T4 16GB, phù hợp với điều kiện phần cứng thực tế của nghiên cứu. Đồng thời, vì cả hai mô hình đều được huấn luyện trên cùng một bộ dữ liệu và trong cùng một môi trường tính toán, kết quả so sánh giữa chúng có cơ sở khách quan hơn.

- **Đánh giá mô hình (Evaluation):** Để đánh giá chất lượng đầu ra của mô hình, đề tài không sử dụng các phương pháp đối sánh văn bản truyền thống như BLEU hay ROUGE, vì các chỉ số này không phù hợp với bài toán giải toán tự luận, nơi một lời giải đúng có thể được diễn đạt theo nhiều cách khác nhau. Thay vào đó, đề tài xây dựng một quy trình đánh giá gồm hai hướng bổ sung cho nhau. Thứ nhất là các chỉ số khớp chính xác (Hard Metrics), dùng để kiểm tra mức độ đúng của đáp án cuối. Thứ hai là hệ thống LLM-as-a-Judge, trong đó một mô hình ngôn ngữ khác đóng vai trò giám khảo để chấm điểm lời giải

dựa trên các tiêu chí như độ chính xác toán học, chất lượng lập luận, tính đầy đủ của cấu trúc và mức độ tuân thủ định dạng trình bày. Nhờ đó, việc đánh giá không chỉ dừng lại ở việc xác định mô hình trả lời đúng hay sai, mà còn cho phép phân tích sâu hơn về chất lượng suy luận và cách mô hình trình bày lời giải.

Tóm lại, cách tiếp cận của đề tài được xây dựng theo hướng kết hợp chặt chẽ giữa dữ liệu, mô hình và hệ thống đánh giá. Bộ dữ liệu được thiết kế để hỗ trợ mô hình học suy luận từng bước; QLoRA được lựa chọn để bảo đảm tính khả thi về mặt phần cứng; còn phương pháp đánh giá được xây dựng theo hướng phù hợp hơn với đặc thù của bài toán toán học. Nhờ đó, nghiên cứu không chỉ dừng lại ở việc thử nghiệm mô hình, mà còn hình thành một quy trình tương đối hoàn chỉnh cho bài toán tự động hóa giải bài tập Xác suất – Thống kê bằng tiếng Việt.

## 5. Đóng góp của nghiên cứu

Nghiên cứu này có một số đóng góp chính trên các phương diện dữ liệu, mô hình, đánh giá và công bố học thuật.

Thứ nhất, đề tài đã xây dựng được một bộ dữ liệu tiếng Việt chuyên biệt cho bài toán giải bài tập Xác suất – Thống kê ở bậc đại học. Bộ dữ liệu được số hóa, làm sạch và chuẩn hóa theo cấu trúc gồm đề bài, dữ kiện toán học ở dạng LaTeX và lời giải chi tiết theo từng bước. Đây là nền tảng trực tiếp phục vụ quá trình tinh chỉnh mô hình trong bối cảnh nguồn dữ liệu toán học tiếng Việt còn hạn chế.

Thứ hai, đề tài đã triển khai quá trình tinh chỉnh có giám sát trên hai mô hình ngôn ngữ lớn mã nguồn mở là Gemma-7B-it và Qwen2.5-Math bằng kỹ thuật QLoRA. Việc áp dụng cùng một bộ dữ liệu và cùng một điều kiện huấn luyện giúp tạo cơ sở so sánh tương đối nhất quán giữa mô hình đa dụng và mô hình có định hướng toán học.

Thứ ba, đề tài đã chuẩn hóa đầu ra của mô hình theo cấu trúc lời giải từng bước, thông qua các thành phần như /buoc1, /buoc2, /ketluan và /dapan. Cách tổ chức này giúp mô hình học tốt hơn tiến trình suy luận, đồng thời hỗ trợ thuận lợi cho việc đọc, phân tích và đánh giá lời giải.

Thứ tư, đề tài đã xây dựng một quy trình đánh giá kết hợp giữa các chỉ số khớp chính xác và phương pháp *LLM-as-a-Judge*. Nhờ đó, đầu ra của mô hình được xem xét không chỉ ở đáp án cuối mà còn ở các khía cạnh như tính logic, độ chính xác toán học và mức độ đầy đủ của lời giải.

Cuối cùng, nghiên cứu đã được công bố trong bài báo khoa học tại Hội thảo quốc gia về Khoa học tự nhiên và Ứng dụng trong thời đại số (NSA 2026). Đây là cơ sở cho thấy hướng nghiên cứu có giá trị học thuật và có khả năng tiếp tục mở rộng trong các bài toán ứng dụng trí tuệ nhân tạo trong giáo dục.

## **6. Ý nghĩa thực tiễn**

### **Ý nghĩa khoa học**

Về mặt học thuật, đề tài góp phần bổ sung thêm tư liệu và kết quả thực nghiệm cho hướng nghiên cứu ứng dụng mô hình ngôn ngữ lớn vào giải toán bằng tiếng Việt, đặc biệt trong miền kiến thức Xác suất – Thống kê ở bậc đại học. Thay vì chỉ dừng ở việc thử nghiệm một mô hình đơn lẻ, nghiên cứu tiến hành đối sánh hai mô hình có định hướng khác nhau, qua đó cung cấp thêm góc nhìn về khả năng thích nghi của mô hình đa dụng và mô hình chuyên biệt khi được tinh chỉnh trên cùng một miền dữ liệu.

Bên cạnh đó, nghiên cứu cũng cho thấy việc tổ chức dữ liệu và đầu ra theo cấu trúc lời giải từng bước có ý nghĩa rõ rệt đối với bài toán giải toán tự luận. Kết quả này gợi mở rằng trong các tác vụ đòi hỏi suy luận nhiều bước, chất lượng dữ liệu và cách chuẩn hóa lời giải có thể ảnh hưởng mạnh đến khả năng học và biểu diễn tri thức của mô hình.

Ngoài ra, cách kết hợp giữa đánh giá đáp án cuối với đánh giá chất lượng suy luận bằng *LLM-as-a-Judge* cũng mang ý nghĩa phương pháp luận. Cách tiếp cận này giúp việc đánh giá trở nên phù hợp hơn với đặc thù của bài toán toán học, nơi chất lượng lời giải không thể phản ánh đầy đủ chỉ bằng các chỉ số đối sánh văn bản bề mặt.

### **Ý nghĩa ứng dụng**

Về mặt ứng dụng, đề tài tạo cơ sở cho việc phát triển các hệ thống hỗ trợ học tập có khả năng giải thích lời giải bài tập Xác suất – Thống kê bằng tiếng Việt theo từng bước. Điều này có thể hỗ trợ người học không chỉ ở việc kiểm tra đáp án mà còn ở việc hiểu cách làm, cách áp dụng công thức và mối liên hệ giữa các dữ kiện trong bài toán.

Đối với giảng viên và cơ sở đào tạo, kết quả của đề tài có thể được tham khảo trong việc xây dựng đáp án mẫu, ngân hàng lời giải hoặc các công cụ hỗ trợ dạy và học. Việc tự động hóa một phần quá trình sinh lời giải có thể giúp giảm khối lượng công việc thủ công, đồng thời tạo điều kiện để tập trung nhiều hơn vào việc tổ chức nội dung giảng dạy và hỗ trợ người học.



Đối với cộng đồng nghiên cứu và phát triển AI, đề tài cung cấp một quy trình triển khai tương đối hoàn chỉnh, từ xây dựng dữ liệu, tinh chỉnh mô hình đến đánh giá đầu ra. Quy trình này có thể được tham khảo và điều chỉnh để áp dụng cho các bài toán giáo dục khác có đặc điểm tương tự.

### **Ý nghĩa chiến lược**

Về phương diện triển khai, nghiên cứu cho thấy việc ứng dụng các mô hình ngôn ngữ lớn mã nguồn mở trong giáo dục là khả thi ngay cả khi sử dụng hạ tầng phần cứng ở mức phổ thông, nhờ các kỹ thuật tinh chỉnh tham số hiệu quả như QLoRA. Điều này góp phần làm giảm rào cản kỹ thuật và chi phí trong quá trình đưa AI vào môi trường học tập.

Bên cạnh đó, việc ưu tiên sử dụng mô hình mã nguồn mở cũng có ý nghĩa nhất định về tính chủ động công nghệ và bảo mật dữ liệu. So với việc phụ thuộc hoàn toàn vào các nền tảng bên ngoài, cách tiếp cận này giúp các cơ sở đào tạo có thêm lựa chọn trong việc phát triển các công cụ hỗ trợ học tập phù hợp với nhu cầu thực tế và điều kiện triển khai của mình.

Nhìn chung, ý nghĩa của đề tài không chỉ nằm ở kết quả thực nghiệm đạt được, mà còn ở việc gợi mở một hướng triển khai khả thi cho các ứng dụng AI trong giáo dục đại học, đặc biệt đối với các môn học có yêu cầu suy luận và trình bày lời giải theo từng bước.

## CHƯƠNG 1: TỔNG QUAN NGHIÊN CỨU VÀ NỀN TẢNG LÝ THUYẾT

### 1.1. PHÂN TÍCH BÀI TOÁN ỨNG DỤNG

Sự phát triển vượt bậc của Trí tuệ Nhân tạo, đặc biệt là các Mô hình ngôn ngữ lớn, đã tạo ra những bước ngoặt mang tính cách mạng trong lĩnh vực Công nghệ giáo dục. Tuy nhiên, việc ứng dụng trực tiếp LLM vào giải quyết các bài toán đòi hỏi tư duy logic chặt chẽ và suy luận toán học nhiều bước vẫn là một thách thức kỹ thuật lớn chưa được giải quyết triệt để. Rào cản căn bản nhất hiện nay là hiện tượng “ảo giác” (hallucination) – khi mô hình đưa ra các bước lập luận thiếu cơ sở hoặc tính toán sai lệch nhưng trình bày dưới văn phong vô cùng tự tin và thuyết phục.

Xác suất Thống kê là một học phần cốt lõi tại các trường đại học, đòi hỏi người học không chỉ có kỹ năng tính toán chính xác mà còn cần tư duy phân tích sự kiện và mô hình hóa các vấn đề trừu tượng như biến cố, xác suất điều kiện hay phân phối chuẩn. Khó khăn đặc thù đối với LLM khi giải môn học này thể hiện qua các dạng lỗi phổ biến: nhảy cóc bước giải (Step Skipping), áp dụng nhầm định lý (ví dụ: dùng phân phối  $Z$  thay vì Student khi cỡ mẫu nhỏ), hoặc sai sót số học cơ bản ở bước tính toán cuối dù chuỗi lập luận trước đó hoàn toàn đúng hướng. Điều này đặt ra yêu cầu mô hình phải có khả năng trình bày quy trình tính toán có hệ thống theo tư duy từng bước (step-by-step reasoning), thay vì chỉ đưa ra đáp án cuối cùng.


Mặc dù các mô hình thương mại mã nguồn đóng hàng đầu như GPT-4 hay Claude đã chứng minh năng lực giải toán xuất sắc, việc phụ thuộc hoàn toàn vào chúng lại kéo theo nhiều hệ lụy: chi phí vận hành API đắt đỏ, nguy cơ rò rỉ dữ liệu học thuật khi gửi bài toán lên máy chủ bên thứ ba, và trạng thái “hộp đen” khiến người dùng không thể kiểm soát hay can thiệp vào quy trình suy luận bên trong của mô hình.

Xuất phát từ thực tiễn đó, nghiên cứu này tập trung vào việc tinh chỉnh hai mô hình mã nguồn mở tiên tiến – Gemma-7B-it và Qwen2.5-Math – để chuyên biệt hóa cho bài toán giải XSTK tiếng Việt theo cấu trúc suy luận chuỗi (Chain-of-Thought). Đây không chỉ là giải pháp cho bài toán tự chủ công nghệ mà còn mang lại giá trị ứng dụng thực tiễn cao: tạo ra một trợ lý học tập minh bạch, chính xác, có khả năng hoạt động nội bộ (on-premise) mà không phụ thuộc vào các dịch vụ đám mây nước ngoài.

## 1.2. NỀN TẢNG LÝ THUYẾT

### 1.2.1. Tổng quan về mô hình ngôn ngữ lớn và Kiến trúc Transformer

Mô hình ngôn ngữ lớn (Large Language Models – LLM) là các mạng nơ-ron học sâu sở hữu quy mô khổng lồ, từ hàng tỷ đến hàng nghìn tỷ tham số. Các mô hình này được huấn luyện trước (pre-trained) trên lượng dữ liệu văn bản đồ sộ nhằm thấu hiểu ngữ nghĩa và sinh ra ngôn ngữ tự nhiên một cách lưu loát.



Hình 1. 1. Kiến trúc tổng thể của mô hình Transformer[6]

Kiến trúc lõi tạo nên sự thành công của hầu hết các mô hình ngôn ngữ lớn hiện đại là Transformer, được Vaswani và cộng sự giới thiệu vào năm 2017 trong công trình “*Attention Is All You Need*” [6]. So với các kiến trúc trước đó như mạng tích chập (CNN) hay mạng nơ-ron hồi quy (RNN), Transformer tạo ra một bước chuyển quan trọng trong cách xử lý chuỗi dữ liệu ngôn ngữ. Điểm

khác biệt nổi bật nhất của kiến trúc này là không còn phụ thuộc vào cơ chế xử lý tuần tự truyền thống, mà thay vào đó sử dụng cơ chế *Tự chú ý* (*Self-Attention*) để tính toán mức độ liên hệ giữa các phần tử trong chuỗi đầu vào.

#### 1.2.1.1 Cơ chế Self-Attention

Cơ chế Self-Attention cho phép mô hình xem xét đồng thời toàn bộ các từ hoặc token trong câu, thay vì phải xử lý lần lượt từng phần tử như RNN. Nhờ đó, mô hình có thể xác định được mức độ quan trọng của từng từ đối với các từ còn lại, ngay cả khi chúng nằm cách xa nhau trong chuỗi. Đây là ưu điểm đặc biệt quan trọng đối với các bài toán ngôn ngữ tự nhiên nói chung và các bài toán toán học nói riêng, nơi mà mối liên hệ giữa các ký hiệu, dữ kiện và điều kiện bài toán có thể xuất hiện ở nhiều vị trí khác nhau nhưng vẫn cần được mô hình nắm bắt chính xác.

Về mặt toán học, trọng số của cơ chế Self-Attention được tính toán thông qua ba ma trận chiếu là Query (**Q**), Key (**K**) và Value (**V**). Đầu ra của attention được xác định theo công thức:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (1.1)$$

Trong đó, **Q** biểu diễn truy vấn của từng token, **K** biểu diễn đặc trưng dùng để đối chiếu, còn **V** chứa thông tin được tổng hợp để tạo ra đầu ra cuối cùng. Thành phần  $QK^T$  phản ánh mức độ tương quan giữa các token trong chuỗi. Sau đó, kết quả này được chuẩn hóa bằng hàm *softmax* để thu được phân phối trọng số attention, từ đó xác định token nào cần được chú ý nhiều hơn trong quá trình biểu diễn ngữ nghĩa.

Trong công thức trên,  $d_k$  là số chiều của vector Key, còn hệ số  $1/\sqrt{d_k}$  có vai trò chuẩn hóa giá trị tích vô hướng giữa **Q** và **K**. Việc đưa thêm hệ số này giúp hạn chế tình trạng các giá trị trong ma trận attention trở nên quá lớn khi số chiều vector tăng lên, từ đó giữ cho quá trình huấn luyện ổn định hơn. Nói cách khác, đây là một cơ chế kỹ thuật quan trọng nhằm tránh hiện tượng gradient quá nhỏ hoặc quá lớn trong quá trình lan truyền ngược.

Để hiểu rõ hơn cách thức hoạt động, ta có thể mô tả chi tiết quy trình tính toán attention như sau:

- **Chiếu tuyến tính:** Mỗi token đầu vào  $x_i$  được nhân với ba ma trận trọng số  $W^Q$ ,  $W^K$ ,  $W^V$  để tạo ra ba vector:

$$\mathbf{q}_i = \mathbf{x}_i \mathbf{W}^Q \quad (1.2)$$

$$\mathbf{k}_i = \mathbf{x}_i \mathbf{W}^K \quad (1.3)$$

$$\mathbf{v}_i = \mathbf{x}_i \mathbf{W}^V \quad (1.4)$$

- **Tính điểm tương quan:** Với mỗi cặp token  $(i, j)$ , điểm attention được tính bằng tích vô hướng của  $\mathbf{q}_i$  và  $\mathbf{k}_j$ , sau đó chia cho  $\sqrt{d_k}$ :

$$score(i, j) = \frac{\mathbf{q}_i \times \mathbf{k}_j}{\sqrt{d_k}} \quad (1.5)$$

- **Chuẩn hóa trọng số:** Áp dụng hàm softmax theo chiều các token nguồn để thu được phân phối xác suất:

$$\alpha_{ij} = \frac{\exp(score(i, j))}{\sum_{k=1}^n \exp(score(i, k))} \quad (1.6)$$

- **Tổng hợp đầu ra:** Vector đầu ra cho token  $i$  là tổ hợp tuyến tính có trọng số của các vector value:

$$\mathbf{o}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j \quad (1.7)$$

#### 1.2.1.2. Multi-Head Attention

Bên cạnh cơ chế Self-Attention cơ bản, Transformer còn sử dụng cơ chế *Chú ý đa đầu* (Multi-Head Attention). Thay vì chỉ thực hiện một phép attention duy nhất, mô hình thực hiện nhiều phép attention song song trên các không gian biểu diễn khác nhau, sau đó ghép nối các kết quả lại với nhau.

Công thức toán học của Multi-Head Attention được biểu diễn như sau:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (1.8)$$

Trong đó mỗi đầu attention được tính:

$$\text{head}_i = \text{Attention}(\mathbf{Q} \mathbf{W}_i^Q, \mathbf{K} \mathbf{W}_i^K, \mathbf{V} \mathbf{W}_i^V) \quad (1.9)$$

Cách làm này giúp mô hình học được nhiều kiểu quan hệ ngữ nghĩa cùng lúc, chẳng hạn như quan hệ ngữ pháp, quan hệ ngữ nghĩa hoặc quan hệ logic giữa các thành phần trong chuỗi. Đối với bài toán toán học, Multi-Head Attention đặc biệt hữu ích vì nó cho phép mô hình đồng thời theo dõi nhiều mối liên hệ khác nhau, ví dụ như mối liên hệ giữa dữ kiện và công thức, giữa giả thiết và kết luận, hoặc giữa các bước biến đổi trung gian trong lời giải.

#### 1.2.1.3. Positional Encoding

Một thành phần quan trọng khác của Transformer là *Mã hóa vị trí* (Positional Encoding). Do cơ chế Self-Attention xử lý tất cả các token song song nên mô hình không có khả năng tự nhiên nhận biết thứ tự của các từ trong câu. Để

khắc phục điều này, Transformer thêm vào mỗi vector embedding đầu vào một vector mã hóa vị trí dựa trên hàm sin và cosin:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (1.10)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (1.11)$$

Trong đó  $pos$  là vị trí của token trong chuỗi,  $i$  là chỉ số chiều và  $d_{model}$  là số chiều của vector embedding. Cách mã hóa này cho phép mô hình học được các mẫu vị trí tương đối giữa các token, đồng thời có khả năng tổng quát hóa cho các chuỗi dài hơn chuỗi huấn luyện.

#### 1.2.1.4. Feed-Forward Networks và Layer Normalization

Ngoài ra, Transformer còn được kết hợp với các thành phần khác như *Mạng truyền thẳng* (Feed-Forward Networks) và *Chuẩn hóa lớp* (Layer Normalization).

Mạng Feed-Forward bao gồm hai phép biến đổi tuyến tính với hàm kích hoạt ReLU ở giữa:

$$\text{FFN}(\mathbf{x}) = \max(0, \mathbf{x}\mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2 \quad (1.12)$$

Feed-Forward Network giúp mô hình tiếp tục biến đổi và trích xuất đặc trưng sau bước attention, trong khi Layer Normalization góp phần ổn định quá trình huấn luyện, giúp mô hình hội tụ tốt hơn khi số lớp và số tham số tăng lên.

Layer Normalization chuẩn hóa các giá trị activation trong mỗi lớp theo công thức:

$$\text{LayerNorm}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \quad (1.13)$$

Trong đó  $\mu$  và  $\sigma^2$  là trung bình và phương sai của các activation,  $\gamma$  và  $\beta$  là các tham số học được, và  $\epsilon$  là hằng số nhỏ để tránh chia cho 0.

Sự kết hợp giữa các thành phần này tạo nên một kiến trúc vừa mạnh về khả năng biểu diễn ngữ nghĩa, vừa hiệu quả trong quá trình tối ưu.


Nhờ các đặc điểm trên, Transformer đã trở thành nền tảng của hầu hết các mô hình ngôn ngữ lớn hiện đại. Đối với phạm vi nghiên cứu của khóa luận này, kiến trúc Transformer có ý nghĩa đặc biệt quan trọng vì nó cung cấp nền tảng để mô hình nhận diện các cấu trúc toán học, liên kết các dữ kiện trong đề bài và hỗ trợ quá trình suy luận nhiều bước. Đây chính là cơ sở để các mô hình như Gemma-7B-it và Qwen2.5-Math có thể tiếp tục được tinh chỉnh nhằm thích nghi tốt hơn với bài toán giải Xác suất – Thống kê bằng tiếng Việt.

### 1.2.2. Kiến trúc và đặc điểm của các mô hình nghiên cứu

Căn cứ vào yêu cầu đặc thù của bài toán – đòi hỏi năng lực xử lý đồng thời ngôn ngữ tự nhiên tiếng Việt lẫn hệ thống ký hiệu toán học phức tạp – nghiên cứu lựa chọn hai kiến trúc mô hình mã nguồn mở tiêu biểu ở phân khúc 7 tỷ tham số để tiến hành tinh chỉnh và đối sánh.

#### 1.2.2.1. Gemma-7B-it (Mô hình đa dụng tổng quát)

Gemma-7B-it là mô hình ngôn ngữ mã nguồn mở do Google DeepMind phát triển và phát hành đầu năm 2024, kế thừa trực tiếp các công nghệ lõi từ họ mô hình Gemini. Đây là phiên bản đã được tinh chỉnh theo chỉ thị (instruction-tuned) nhằm tối ưu hóa khả năng giao tiếp và đáp ứng các yêu cầu đa dạng của người dùng.



Hình 1. 2. Tổng quan kiến trúc mô hình Gemma-7B-it

Điểm nhấn kỹ thuật của Gemma-7B-it nằm ở việc ứng dụng cơ chế **Multi-Query Attention (MQA)**: thay vì duy trì  $h$  cặp Key-Value riêng biệt cho  $h$  đầu attention như Multi-Head Attention truyền thống, MQA chia sẻ một bộ Key-Value duy nhất cho tất cả các đầu query.

Về mặt toán học, nếu Multi-Head Attention truyền thống yêu cầu lưu trữ  $h \times d_k$  tham số cho Key và Value, thì MQA chỉ cần  $d_k$  tham số cho mỗi loại. Điều này giảm đáng kể không gian bộ nhớ KV Cache từ  $O(h \cdot d_k \cdot L)$  xuống  $O(d_k \cdot L)$  trong quá trình suy luận, trong đó  $L$  là độ dài chuỗi. Cơ chế này giúp giảm đáng kể lượng bộ nhớ KV Cache cần thiết trong quá trình suy luận (inference) mà không làm suy giảm đáng kể chất lượng biểu diễn.

Mô hình sở hữu cửa sổ ngữ cảnh rộng (8.192 token) cùng bộ từ vựng khổng lồ lên tới 256.000 token, đảm bảo khả năng xử lý các đề bài dài và đa dạng

ngôn ngữ. Kích thước từ vựng lớn này đặc biệt quan trọng trong việc biểu diễn hiệu quả các ký tự Unicode tiếng Việt và ký hiệu toán học LaTeX mà không cần phải chia nhỏ thành nhiều token con.

Gemma-7B-it còn được trang bị các kỹ thuật tối ưu hóa hiện đại như:

- **RoPE (Rotary Position Embedding):** Thay thế cho Positional Encoding truyền thống, RoPE mã hóa vị trí tương đối trực tiếp vào trọng số attention, giúp mô hình tổng quát hóa tốt hơn cho các chuỗi dài.


- **SwiGLU Activation:** Hàm kích hoạt được cải tiến thay thế cho ReLU truyền thống, được chứng minh mang lại hiệu suất tốt hơn trong các mô hình ngôn ngữ lớn.

- **RMSNorm:** Biến thể đơn giản hóa của Layer Normalization, giảm chi phí tính toán trong khi vẫn duy trì hiệu quả chuẩn hóa.

Trong bối cảnh nghiên cứu này, Gemma-7B-it đóng vai trò đại diện cho nhóm LLM tổng quát (general-purpose) – nơi năng lực phân tích ngữ nghĩa đề bài tiếng Việt và khả năng diễn giải lời giải tự nhiên, mạch lạc được đặt lên hàng đầu.

#### 1.2.2.2. Qwen2.5-Math (Mô hình chuyên biệt Toán học)

Qwen2.5-Math là kiến trúc chuyên biệt cho lĩnh vực logic và toán học, do Alibaba Cloud phát triển. Khác với các LLM đa dụng, bộ dữ liệu tiền huấn luyện của Qwen2.5-Math bao gồm hàng trăm tỷ token toán học từ các nguồn học thuật chất lượng cao, bao gồm bài thi toán học quốc tế, giáo trình đại học và code toán học.



Hình 1. 3. Tổng quan kiến trúc mô hình Qwen2.5-Math



Về mặt cơ chế attention, Qwen2.5-Math sử dụng **Grouped-Query Attention (GQA)**: các đầu query được phân thành  $g$  nhóm, mỗi nhóm chia sẻ một cặp Key-Value.

Cụ thể, nếu có  $h$  đầu attention được chia thành  $g$  nhóm ( $g < h$ ), thì:

$$\text{GQA} = \text{Concat}(\text{head}_{1,1}, \dots, \text{head}_{1,k}, \dots, \text{head}_{g,k}) \mathbf{W}^0 \quad (1.14)$$

Trong đó mỗi nhóm có  $k = h/g$  đầu attention chia sẻ cùng một cặp Key-Value. So với MQA, GQA cung cấp điểm cân bằng tốt hơn giữa hiệu quả bộ nhớ và chất lượng biểu diễn – đặc biệt phù hợp với các bài toán đòi hỏi theo dõi nhiều biến số song song như thống kê nhiều biến. Bộ nhớ KV Cache cần thiết là  $O(g \cdot d_k \cdot L)$ , nằm giữa Multi-Head ( $h$  nhóm) và Multi-Query (1 nhóm).

Qwen2.5-Math còn được huấn luyện với các kỹ thuật chuyên biệt:

- **Tool-Integrated Reasoning (TIR)**: Tích hợp khả năng gọi công cụ tính toán bên ngoài (Python interpreter, symbolic math engines) để đảm bảo độ chính xác tuyệt đối của các phép toán số học phức tạp.

- **Step-by-Step Verification**: Cơ chế tự kiểm tra từng bước lập luận trung gian, giúp phát hiện sớm các lỗi logic trước khi lan truyền đến kết quả cuối.

- **LaTeX-aware Tokenization**: Bộ tokenizer được tối ưu hóa riêng để xử lý các biểu thức toán học LaTeX, giảm số lượng token cần thiết để biểu diễn công thức và giảm thiểu lỗi parse.

Nhờ nền tảng tri thức chuyên sâu này, Qwen2.5-Math sở hữu năng lực vượt trội trong việc phân tích đồ thị tư duy logic đa bước, nhận diện và tái tạo chính xác các công thức LaTeX, cũng như xử lý các phép toán liên quan đến phân phối xác suất.


Bảng 1.1. Đặc điểm kiến trúc của Gemma-7B-it và Qwen2.5-Math

| Đặc điểm kỹ thuật  | Gemma-7B-it                 | Qwen2.5-Math                  |
|--------------------|-----------------------------|-------------------------------|
| Quy mô tham số     | 7 tỷ                        | 7 tỷ                          |
| Cơ chế Attention   | Multi-Query Attention (MQA) | Grouped-Query Attention (GQA) |
| Cửa sổ ngữ cảnh    | 8.192 token                 | 4.096 token                   |
| Kích thước từ vựng | 256.000 token               | 152.064 token                 |

|                    |                                |                                    |
|--------------------|--------------------------------|------------------------------------|
| Đặc trưng cốt lõi  | Mô hình tổng quát đa ngôn ngữ  | Chuyên sâu toán học & LaTeX        |
| Trọng tâm ứng dụng | Diễn giải ngữ nghĩa tiếng Việt | Suy luận logic & tính toán đa bước |
| Chứng nhận         | Gemma License                  | Apache 2.0                         |

### 1.2.3. Kỹ thuật Chain-of-Thought Prompting

Chain-of-Thought (CoT) Prompting là phương pháp hướng dẫn LLM cải thiện khả năng suy luận trên các bài toán phức tạp, được Wei và cộng sự đề xuất năm 2022. Ý tưởng cốt lõi là thay vì yêu cầu mô hình đưa ra đáp án trực tiếp, CoT buộc mô hình sinh ra một chuỗi các bước suy luận trung gian (intermediate reasoning steps) trước khi đưa ra kết quả cuối cùng, mô phỏng quá trình tư duy có hệ thống của con người khi giải toán.



Hình 1. 4. Minh họa kỹ thuật Chain-of-Thought Prompting

#### 1.2.3.1. Nguyên lý hoạt động của CoT

Về mặt lý thuyết, CoT hoạt động hiệu quả nhờ cơ chế phân rã (decomposition): một bài toán phức tạp được chia thành các bước con độc lập, dễ xử lý hơn. Khi tự viết ra các bước trung gian, mô hình đồng thời tự kiểm tra logic của chính mình trước khi đi đến kết luận, từ đó giảm đáng kể xác suất xảy ra lỗi nhảy cóc bước giải.

Nghiên cứu của Wei và cộng sự chỉ ra rằng CoT đặc biệt hiệu quả với các bài toán yêu cầu:

- **Suy luận nhiều bước:** Các bài toán không thể giải quyết bằng một phép tính đơn lẻ mà cần chuỗi các bước logic liên tiếp.
- **Kết hợp thông tin phân tán:** Các dữ kiện cần thiết nằm rải rác trong đề bài và phải được tổng hợp lại.
- **Áp dụng tri thức chuyên môn:** Cần nhận diện đúng công thức, định lý hay phương pháp tiếp cận phù hợp.

Các thực nghiệm cho thấy việc áp dụng CoT có thể cải thiện độ chính xác từ 15-20% đối với các bài toán phức tạp so với phương pháp prompt trực tiếp.

#### 1.2.3.2. Các biến thể của CoT

Kể từ khi được đề xuất, CoT đã có nhiều biến thể được phát triển:

- **Few-Shot CoT:** Cung cấp một vài ví dụ mẫu có lời giải chi tiết để mô hình học theo pattern. Phương pháp này hiệu quả nhưng đòi hỏi phải chuẩn bị kỹ các ví dụ minh họa chất lượng cao.
- **Zero-Shot CoT:** Chỉ thêm câu kích hoạt đơn giản như “Hãy suy nghĩ từng bước” (“Let’s think step by step”) mà không cần ví dụ mẫu. Phương pháp này đơn giản hơn nhưng hiệu quả thấp hơn Few-Shot CoT.
- **Self-Consistency CoT:** Sinh ra nhiều chuỗi suy luận khác nhau cho cùng một bài toán, sau đó bầu chọn đáp án xuất hiện nhiều nhất (majority voting). Cách làm này tăng độ tin cậy nhưng tốn nhiều chi phí tính toán hơn.
- **Least-to-Most Prompting:** Chia bài toán phức tạp thành các bài toán con đơn giản hơn, giải quyết tuần tự từ đơn giản đến phức tạp, sử dụng kết quả của bước trước làm đầu vào cho bước sau.

#### 1.2.3.3. Hiện thực hóa CoT trong nghiên cứu

Trong nghiên cứu này, cấu trúc CoT được hiện thực hóa qua hệ thống thẻ phân cấp trong dữ liệu huấn luyện và câu lệnh hệ thống (system prompt). Mỗi lời giải được phân rã chặt chẽ theo ba nhãn:

- **/buoc1:** Phân tích giả thiết, đặt tên đại lượng và xác định phương pháp tiếp cận.
- **/buoc2:** Thay số, áp dụng công thức/định lý và thực hiện tính toán trung gian.

- /ketluan: Tổng hợp kết quả và trả lời đúng trọng tâm câu hỏi.

Ví dụ cụ thể về cấu trúc này:

Câu hỏi: Một lớp có 30 học sinh, trong đó có 18 nam và 12 nữ. Chọn ngẫu nhiên 3 học sinh. Tính xác suất để trong 3 học sinh được chọn có ít nhất 1 học sinh nữ.

/buoc1

- Không gian mẫu: Chọn 3 học sinh từ 30 học sinh
- Số phần tử không gian mẫu:  $n(\Omega) = C(30,3)$
- Gọi A là biến cố "chọn được ít nhất 1 học sinh nữ"
- Biến cố đối:  $\bar{A}$  là "chọn được toàn học sinh nam"

/buoc2

- Tính  $n(\Omega) = C(30,3) = 30!/(3! \times 27!) = 4060$
- Tính  $n(\bar{A}) = C(18,3) = 18!/(3! \times 15!) = 816$
- Áp dụng công thức xác suất biến cố đối:  $P(A) = 1 - P(\bar{A}) = 1 - \frac{n(\bar{A})}{n(\Omega)}$
- $P(A) = 1 - 816/4060 = 1 - 0.201 = 0.799$

/ketluan

Xác suất để trong 3 học sinh được chọn có ít nhất 1 học sinh nữ là 0.799 (hay 79.9%).


Phương pháp này đặc biệt phù hợp với đặc thù của môn Xác suất Thống kê, nơi mỗi bài toán thường yêu cầu từ 3 đến 7 bước lập luận và tính toán liên tiếp. Ép mô hình suy luận theo cấu trúc thể CoT giúp hạn chế đáng kể tình trạng ảo giác số học (Arithmetic Hallucination) và lỗi sai số lũy kế (Cascading Errors) trong các bài toán có chuỗi tính toán dài.

Ngoài ra, việc chuẩn hóa cấu trúc đầu ra còn mang lại lợi ích về mặt đánh giá: các lời giải tuân theo format thống nhất dễ dàng được parse và chấm điểm tự động, đồng thời giúp người học dễ theo dõi logic suy luận của mô hình.

#### 1.2.4. Tinh chỉnh tham số hiệu quả với LoRA và QLoRA

Huấn luyện lại toàn bộ một LLM (Full Fine-tuning) với hàng tỷ tham số đòi hỏi tài nguyên GPU khổng lồ (thường cần hàng chục đến hàng trăm GB VRAM), hoàn toàn vượt ngoài khả năng của phần cứng cá nhân hay máy chủ phổ thông. Để giải quyết rào cản này, các kỹ thuật Tinh chỉnh tham số hiệu quả

(**PEFT** – *Parameter-Efficient Fine-Tuning*) được áp dụng, trong đó **LoRA** và **QLoRA** là hai nền tảng then chốt của nghiên cứu.



Hình 1. 5. Mô hình hóa kỹ thuật tinh chỉnh LoRA và QLoRA [7]

#### 1.2.4.1. LoRA (Low-Rank Adaptation)

Được đề xuất năm 2021 bởi Hu và cộng sự [7], nguyên lý cốt lõi của LoRA dựa trên giả thuyết: sự thay đổi trọng số cần thiết khi tinh chỉnh cho một tác vụ cụ thể có thể được xấp xỉ bằng một ma trận có hạng thấp (low-rank matrix).

Do đó, thay vì cập nhật toàn bộ ma trận trọng số  $W_0$  có kích thước  $d \times k$ , LoRA đóng băng  $W_0$  và chỉ huấn luyện hai ma trận phân rã hạng thấp  $A$  có kích thước  $d \times r$  và  $B$  có kích thước  $r \times k$ , với  $r \ll \min(d, k)$ :

$$\Delta W = A \times B \quad (1.15)$$

Trong đó,  $r$  được gọi là rank, là siêu tham số kiểm soát khả năng biểu diễn của adapter. Kỹ thuật này có thể giảm tới 10.000 lần số lượng tham số cần huấn luyện so với Full Fine-tuning, trong khi vẫn duy trì hiệu suất ở mức tương đương.

#### 1.2.4.2. QLoRA (Quantized LoRA)

QLoRA [8] là bước tiến hóa quan trọng từ LoRA, giải quyết triệt để bài toán giới hạn bộ nhớ thông qua ba kỹ thuật tối ưu hóa đồng thời:

- Lượng tử hóa 4-bit NF4 (NormalFloat 4-bit): Nén trọng số mô hình gốc từ 16-bit xuống định dạng NF4. Đây là kiểu dữ liệu được chứng minh về mặt lý thuyết thông tin là tối ưu cho phân phối trọng số của LLM, vốn thường có phân phối gần chuẩn và tập trung quanh 0.

- Lượng tử hóa kép (Double Quantization): Áp dụng lượng tử hóa bổ sung lên chính các hằng số lượng tử hóa (quantization constants), giúp tiết kiệm thêm khoảng 0.4 bit trên mỗi tham số so với lượng tử hóa đơn.

- Trình tối ưu hóa phân trang (Paged Optimizers): Sử dụng bộ nhớ hợp nhất của NVIDIA để di chuyển trạng thái optimizer giữa CPU RAM và GPU VRAM khi cần, từ đó hạn chế lỗi tràn bộ nhớ đột ngột (Out-of-Memory Error) trong quá trình huấn luyện.

Nhờ tổ hợp ba kỹ thuật này, QLoRA cho phép tinh chỉnh các mô hình có 7 tỷ tham số như Gemma-7B-it và Qwen2.5-Math trên GPU phổ thông NVIDIA T4 với 16GB VRAM, trong khi vẫn bảo toàn độ chính xác tiệm cận với huấn luyện toàn phần ở chuẩn 16-bit.

### 1.2.5. Phương pháp LLM-as-a-Judge

Đánh giá chất lượng đầu ra của mô hình ngôn ngữ lớn trong lĩnh vực toán học là một bài toán khó. Các độ đo tự động truyền thống như BLEU hay ROUGE chủ yếu đo lường mức độ trùng lặp từ vựng hoặc cụm từ  $n$ -gram giữa văn bản sinh ra và văn bản tham chiếu. Tuy nhiên, cách đánh giá này chưa phù hợp với các bài toán toán học, bởi một bài toán có thể có nhiều cách trình bày lời giải khác nhau về mặt ngôn từ nhưng vẫn tương đương về mặt logic và cho cùng kết quả đúng. Ngoài ra, trong các bài toán có lời giải từng bước, chất lượng của câu trả lời không chỉ nằm ở đáp án cuối cùng mà còn phụ thuộc vào quá trình suy luận, cách sử dụng công thức và tính nhất quán giữa các bước giải.

Do đó, nghiên cứu này ứng dụng phương pháp LLM-as-a-Judge nhằm đánh giá tự động chất lượng lời giải do mô hình sinh ra. Cụ thể, một mô hình ngôn ngữ lớn tiên tiến được sử dụng như một giám khảo để đọc câu hỏi đầu vào và câu trả lời của mô hình, sau đó đưa ra điểm số đánh giá theo các tiêu chí được thiết kế trước. Trong nghiên cứu này, Gemini 3 Flash Preview được sử dụng thông qua Gemini API để đóng vai trò LLM Judge. Với mỗi mẫu dữ liệu, hệ thống cung cấp cho mô hình giám khảo hai thành phần chính gồm câu hỏi và câu trả lời sinh ra bởi mô hình fine-tuned. Kết quả đánh giá được trả về dưới

dạng JSON, bao gồm điểm logic, điểm toán học, điểm trung bình và nhận xét ngắn gọn.

Hệ thống giám khảo được thiết kế để chấm điểm dựa trên các tiêu chí chính sau:

- **Tính đúng đắn toán học (Math Score):** Tiêu chí này đánh giá mức độ chính xác về mặt toán học của lời giải. Cụ thể, giám khảo xem xét công thức được sử dụng có phù hợp với yêu cầu bài toán hay không, các bước thay số và biến đổi biểu thức có chính xác hay không, kết quả tính toán tại từng bước có đúng không và đáp án cuối cùng có nhất quán với quá trình giải hay không. Một lời giải đạt Math Score cao khi sử dụng đúng công thức, tính toán chính xác và đưa ra kết quả cuối cùng đáng tin cậy.

- **Chất lượng lập luận (Logic Score):** Tiêu chí này đánh giá mức độ hợp lý và mạch lạc của chuỗi suy luận trong lời giải. Giám khảo xem xét các bước giải có được sắp xếp theo trình tự phù hợp hay không, có sự liên kết chặt chẽ giữa giả thiết, công thức, phép biến đổi và kết luận hay không, đồng thời kiểm tra xem mô hình có bỏ qua bước quan trọng, suy luận nhảy cóc hoặc áp dụng sai định lý hay không. Một lời giải đạt Logic Score cao khi quá trình lập luận rõ ràng, liền mạch và kết luận được rút ra hợp lý từ các bước trước đó.

- **Điểm trung bình (Average Score):** Đây là chỉ số tổng hợp phản ánh chất lượng chung của lời giải dựa trên hai tiêu chí chính là Math Score và Logic Score. Trong nghiên cứu này, Average Score được tính bằng trung bình cộng của hai điểm số trên, theo công thức:

$$Average\_Score = \frac{Logic\_Score + Math\_Score}{2} \quad (1.16)$$

- **Phản hồi của giám khảo (Judge Feedback):** Ngoài các điểm số định lượng, mô hình giám khảo còn sinh ra nhận xét ngắn gọn về chất lượng câu trả lời. Phần phản hồi này giúp xác định các lỗi sai phổ biến của mô hình, chẳng hạn như sử dụng sai công thức, tính toán nhầm, lập luận thiếu chặt chẽ, thiếu kết luận hoặc trình bày chưa rõ ràng. Nhờ đó, kết quả đánh giá không chỉ cho biết mô hình đạt bao nhiêu điểm mà còn hỗ trợ phân tích nguyên nhân dẫn đến lỗi sai.

Thang điểm được sử dụng cho mỗi tiêu chí là từ 0 đến 10. Điểm 0 thể hiện câu trả lời hoàn toàn sai, không liên quan hoặc không thể đánh giá. Điểm từ 1 đến 4 phản ánh lời giải có nhiều lỗi nghiêm trọng về lập luận hoặc tính toán. Điểm từ 5 đến 7 cho thấy lời giải có hướng tiếp cận tương đối phù hợp nhưng

vẫn còn một số lỗi ở các bước trung gian hoặc kết quả cuối cùng. Điểm từ 8 đến 10 thể hiện lời giải có lập luận rõ ràng, công thức chính xác, kết quả tính toán hợp lý và đáp ứng tốt yêu cầu của bài toán.

*Prompt yêu cầu LLM Judge đánh giá*

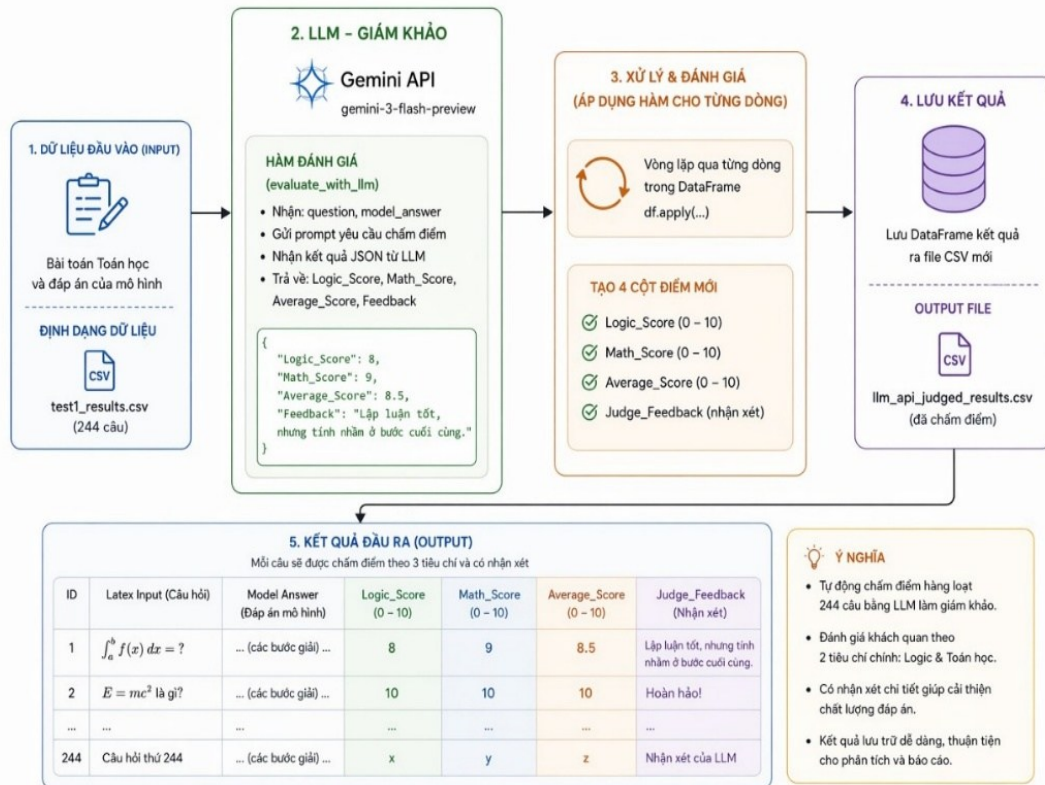
Bạn là một giám khảo chấm điểm toán học chuyên nghiệp. Hãy chấm điểm theo thang điểm từ 0 đến 10 (trừ 1-2 điểm trên 1 bước sai) và theo các tiêu chí sau:

1. Logic\_Score: Các bước lập luận có hợp lý, liên kết chặt chẽ và không nhảy cóc không?
2. Math\_Score: Công thức và kết quả tính toán có chính xác không?
3. Average\_Score: Điểm trung bình cộng của Logic và Math.
4. Feedback: Nhận xét ngắn gọn về lỗi sai (nếu có) hoặc khen ngợi nếu làm tốt.

Cần lưu ý rằng phương pháp LLM-as-a-Judge cũng có những hạn chế nhất định. Chất lượng đánh giá phụ thuộc trực tiếp vào năng lực của mô hình giám khảo, cách thiết kế prompt và độ rõ ràng của tiêu chí chấm điểm. Bản thân mô hình giám khảo vẫn có thể mắc lỗi khi kiểm tra các phép biến đổi toán học phức tạp hoặc thể hiện sự thiên vị đối với một số phong cách trình bày nhất định. Do đó, kết quả từ LLM-as-a-Judge không nên được xem là tuyệt đối, mà cần được sử dụng như một công cụ hỗ trợ đánh giá.

Để tăng tính khách quan, nghiên cứu này kết hợp phương pháp LLM-as-a-Judge với chỉ số Hard Metric, tức là so khớp đáp án số học cuối cùng giữa câu trả lời của mô hình và đáp án tham chiếu. Việc kết hợp hai hướng đánh giá này giúp tận dụng ưu điểm của từng phương pháp: Hard Metric cung cấp thước đo khách quan về độ chính xác (Accuracy) của đáp án cuối cùng được gán nhãn (T/F), trong khi LLM-as-a-Judge cho phép đánh giá sâu hơn về quá trình suy luận và chất lượng lời giải. Nhờ đó, kết quả đánh giá phản ánh toàn diện hơn năng lực của mô hình trong bài toán sinh lời giải toán học bằng tiếng Việt.





Hình 1. 6. Pipeline đánh giá tự động LLM as a Judge

### 1.2.6. Tổng quan các dạng bài toán Xác suất Thống kê cốt lõi

Để xây dựng bộ dữ liệu tinh chỉnh có tính đại diện cao và bao phủ toàn diện chương trình XSTK bậc đại học, nghiên cứu phân loại dữ liệu thành năm nhóm chủ đề nền tảng:

#### 1.2.6.1. Tính xác suất của biến cố:

Bao gồm các bài toán về quy tắc đếm (hoán vị, chỉnh hợp, tổ hợp), công thức cộng/nhân xác suất, xác suất có điều kiện, công thức xác suất đầy đủ và định lý Bayes.

Công thức cốt lõi:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (\text{Công thức cộng}) \quad (1.17)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (\text{Xác suất có điều kiện}) \quad (1.18)$$

$$P(A) = \sum_{i=1}^n P(B_i)P(A|B_i) \quad (\text{Xác suất đầy đủ}) \quad (1.19)$$

$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_{i=1}^n P(B_i)P(A|B_i)} \quad (\text{Bayes}) \quad (1.20)$$

Nhóm này rèn luyện cho mô hình khả năng đọc hiểu ngữ cảnh, xác định đúng biến cố và thiết lập các phương trình xác suất cơ bản.

### 1.2.6.2. Biến ngẫu nhiên và các đặc trưng:

Tập trung vào mô hình hóa các đại lượng ngẫu nhiên rời rạc và liên tục, bao gồm lập bảng phân phối, xác định hàm mật độ, và tính toán các tham số đặc trưng.

Các công thức chính:

$$E(X) = \sum_i x_i P(X = x_i) \quad (\text{Kỳ vọng - rời rạc}) \quad (1.21)$$

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx \quad (\text{Kỳ vọng - liên tục}) \quad (1.22)$$

$$V(X) = E(X^2) - [E(X)]^2 \quad (\text{Phương sai}) \quad (1.23)$$

$$\sigma = \sqrt{V(X)} \quad (\text{Độ lệch chuẩn}) \quad (1.24)$$

Thách thức chính là ép LLM thực hiện chính xác các chuỗi phép tính cộng, nhân hoặc tích phân kéo dài mà không bị lỗi số học.

### 1.2.6.3. Quy luật phân phối xác suất:

Nhận diện và áp dụng các phân phối thông dụng như Nhị thức, Poisson, Chuẩn và Student-t.

Các phân phối quan trọng:

- **Nhị thức:**  $P(X = k) = C_n^k p^k (1 - p)^{n-k}$  với  $E(X) = np$ ,  $V(X) = np(1 - p)$
- **Poisson:**  $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$ , với  $E(X) = V(X) = \lambda$
- **Chuẩn:**  $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ , chuẩn hóa:  $Z = \frac{X-\mu}{\sigma}$
- **Student-t:** Dùng khi  $\sigma$  chưa biết, cỡ mẫu nhỏ ( $n < 30$ )

Yêu cầu mô hình tự động trích xuất dấu hiệu từ đề bài (ví dụ: “lấy mẫu hoàn lại”, “tỷ lệ phế phẩm”) để gọi đúng công thức và thực hiện chuẩn hóa chính xác.

### 1.2.6.4. Ước lượng và Kiểm định:

Bao gồm ước lượng khoảng tin cậy và kiểm định giả thuyết thống kê.

Ước lượng khoảng tin cậy cho trung bình:

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \quad (1.25)$$

Kiểm định giả thuyết:

$$H_0 : \mu = \mu_0 \text{ với } H_1 : \mu \neq \mu_0 \quad (1.26)$$

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \quad (\text{Thống kê kiểm định}) \quad (1.27)$$

Quy tắc quyết định: Bác bỏ  $H_0$  nếu  $|Z| > z_{\alpha/2}$  hoặc  $p\text{-value} < \alpha$ .

Đặc thù nhóm bài này là đòi hỏi tư duy phân nhánh cao: mô hình phải thiết lập cặp giả thuyết ( $H_0, H_1$ ), biện luận dựa trên cỡ mẫu  $n$  và phương sai  $\sigma^2$  để chọn đúng tiêu chuẩn kiểm định, từ đó đưa ra kết luận.

#### 1.2.6.5. Phân tích tương quan và hồi quy:

Đánh giá mối liên hệ tuyến tính giữa các biến thông qua hệ số tương quan Pearson ( $r$ ) và phương trình hồi quy thực nghiệm.

Công thức hồi quy tuyến tính:

$$\hat{y} = a + bx \quad (1.28)$$

$$b = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad (1.29)$$

$$a = \bar{y} - b\bar{x} \quad (1.30)$$

Hệ số tương quan:

$$r = \frac{n \sum xy - \sum x \sum y}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}} \quad (1.31)$$

Đặc thù của nhóm này là dữ liệu đầu vào thường ở dạng bảng biểu đa chiều, đòi hỏi mô hình phải có năng lực phân tách không gian dữ liệu bảng và tổng hợp các biến phức tạp như  $\sum xy, \sum x^2$ .

Việc phân loại chi tiết này giúp đảm bảo bộ dữ liệu huấn luyện có độ phủ đầy đủ, đồng thời tạo điều kiện cho việc phân tích lỗi theo từng nhóm kiến thức trong giai đoạn đánh giá.

### 1.3. TỔNG QUAN VĂN LIỆU VÀ CÔNG TRÌNH LIÊN QUAN

Phần này tổng hợp các nghiên cứu nền tảng nhằm xác định vị trí học thuật của đề tài và làm rõ các khoảng trống nghiên cứu còn tồn tại.

#### 1.3.1. Nghiên cứu quốc tế về năng lực giải toán của LLM

Trên bình diện quốc tế, năng lực giải toán của LLM thường được đo lường qua các bộ dữ liệu chuẩn mực như **GSM8K** (toán tiểu học và trung học cơ sở) và **MATH500** (toán trung học phổ thông). Các nghiên cứu thực nghiệm chỉ ra rằng dù các mô hình hiện đại như GPT-4o đạt độ chính xác trên 90% với GSM8K, hiệu suất của chúng sụt giảm mạnh xuống dưới 60% khi đối mặt với các bài toán trừu tượng cấp đại học đòi hỏi lập luận logic nhiều bước.

Nghiên cứu của Wang và cộng sự (2025) về đánh giá LLM trong giải toán [10] đề xuất phương pháp đánh giá Chuỗi suy luận có cấu trúc (SCoT) và

xác định ba khiếm khuyết phổ biến nhất của LLM khi giải toán: nhảy cóc bước giải (Step Skipping, chiếm 34% trường hợp sai), lỗi số học ở bước cuối (Terminal Arithmetic Error, 28%) và áp dụng sai công thức (Formula Misapplication, 21%).

Đặc biệt, các nghiên cứu cũng chỉ ra sự chênh lệch rõ rệt giữa các kiến trúc: mô hình chuyên biệt **Qwen2.5-Math** đạt 79,9% trên MATH500 – cao hơn đáng kể so với các mô hình đa dụng cùng phân khúc 7B như Llama-3.1-8B (29,0%) hay Gemma-7B-it (24,5%), qua đó khẳng định lợi thế áp đảo của việc tiền huấn luyện chuyên sâu trên dữ liệu toán học.

### 1.3.2. Nghiên cứu tại Việt Nam

Tại Việt Nam, nghiên cứu của Đào Xuân Quý và cộng sự (2023) đánh giá năng lực của ChatGPT trên bộ đề thi THPT Quốc gia (VNHSGE) [2]. Kết quả cho thấy LLM xử lý xuất sắc các câu hỏi mức Nhận biết/Thông hiểu (khoảng 83% chính xác), nhưng hiệu suất giảm sâu còn xấp xỉ 10–15% ở mức Vận dụng cao – minh chứng rõ ràng về giới hạn của LLM khi đối mặt với tư duy suy luận phức tạp trong ngữ cảnh tiếng Việt.

Nhằm khắc phục hiện tượng ảo giác trong môi trường giáo dục đại học, Phạm Văn Khánh và cộng sự (2025) đề xuất hệ thống chatbot toán học ứng dụng kiến trúc RAG [3]. Giải pháp này ép mô hình sinh lời giải dựa trên kho tri thức từ sách giáo khoa, giúp hạn chế việc bịa đặt công thức. Tuy nhiên, RAG phụ thuộc hoàn toàn vào chất lượng kho dữ liệu truy xuất và không giải quyết được căn nguyên vấn đề: bản thân mô hình nền vẫn còn yếu về năng lực suy luận toán học đa bước.

### 1.3.3. Khoảng trống nghiên cứu

Từ các tổng quan trên, có thể xác định ba khoảng trống nghiên cứu lớn còn tồn tại:

- **Thiếu bộ dữ liệu tiếng Việt chuẩn hóa:** Phần lớn các kho dữ liệu mã nguồn mở hỗ trợ huấn luyện toán học chất lượng cao hiện nay (như MetaMathQA, OpenMathInstruct) đều được xây dựng bằng tiếng Anh. Chưa có bộ dữ liệu XSTK tiếng Việt chuyên biệt nào cho môn Xác suất Thống kê cấp đại học với cấu trúc suy luận có hệ thống.

- **Thiếu nghiên cứu đối sánh kiến trúc mô hình:** Chưa có công trình trong nước nào tiến hành đối sánh có hệ thống về khả năng tiếp thu tri thức toán học tiếng Việt giữa một mô hình tổng quát (Gemma) và một mô hình chuyên

biệt toán học (Qwen2.5-Math) thông qua cùng một quy trình tinh chỉnh QLoRA. Việc so sánh này quan trọng để hiểu rõ liệu nền tảng tri thức toán học sẵn có có bù đắp được cho khoảng cách về xử lý tiếng Việt hay không.

- **Thiếu khung đánh giá phù hợp:** Các nghiên cứu trong nước chủ yếu vẫn sử dụng độ đo  $n$ -gram truyền thống hoặc đánh giá nhị phân thủ công, chưa áp dụng phương pháp LLM-as-a-Judge tự động để đánh giá sâu chất lượng chuỗi suy luận. Điều này dẫn đến việc không phát hiện được các lỗi logic tinh vi hoặc đánh giá quá cao các lời giải có kết quả đúng nhưng suy luận sai.

Ba khoảng trống này chính là tiền đề học thuật vững chắc và là động lực cốt lõi để thực hiện đề tài khóa luận này.

## CHƯƠNG 2: THIẾT KẾ GIẢI PHÁP VÀ XÂY DỰNG MÔ HÌNH

### 2.1. PHÂN TÍCH DỮ LIỆU VÀ TIỀN XỬ LÝ

Chất lượng của tập dữ liệu huấn luyện là yếu tố tiên quyết, quyết định năng lực học hỏi và khả năng suy luận của LLM sau khi tinh chỉnh. Đối với chuyên ngành Xác suất Thống kê, dữ liệu không chỉ yêu cầu sự chính xác tuyệt đối về mặt số học mà còn đòi hỏi tính logic chặt chẽ, liền mạch trong từng bước lập luận. Bất kỳ sai sót nào trong tập dữ liệu dù chỉ là một phép tính nhầm hay một bước giải thiếu – đều có nguy cơ bị mô hình tiếp thu và khuếch đại thành hiện tượng ảo giác trong quá trình suy luận thực tế.

#### 2.1.1. Thu thập và xây dựng tập dữ liệu bài tập XSTK

Thay vì lạm dụng các công cụ thu thập dữ liệu tự động (web crawling) từ Internet – vốn tiềm ẩn rủi ro lớn về sai lệch toán học và nhiều định dạng - nghiên cứu này tiếp cận theo phương pháp xây dựng dữ liệu sơ cấp có kiểm soát (Supervised Manual Annotation).

Nguồn dữ liệu gốc được kế thừa trực tiếp từ hệ thống bài tập mẫu và đề thi do Giảng viên hướng dẫn cung cấp, đảm bảo tính học thuật và bám sát chương trình XSTK bậc đại học. Từ hệ thống bài tập thô này, em nghiên cứu tiến hành giải chi tiết, số hóa và biên soạn thủ công để tạo ra bộ dữ liệu tiếng Việt gồm 5.360 mẫu.

| ID | Instruction                | Normal Input                                                                                                                       | Latex Input                                                                                                                                       | Topic                     | Dạng bài | Data Source | Answer_type (Text/Number) | Synthetic_type | Response                                                                                                                                                                                                                                                                                                                          | Answer              |
|----|----------------------------|------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------|----------|-------------|---------------------------|----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------|
| 1  | Hãy giải giúp tôi bài sau: | Cho hai biến cố A và B. Biết rằng $P(A+B)=0.88$ ; $P(A)=0.6$ ; $P(B)=0.7$ . Tính $P(A+B)$ và chứng tỏ A và B độc lập với nhau.     | Cho hai biến cố $A$ và $B$ . Biết rằng $P(A \cup B)=0.88$ ; $P(A)=0.6$ ; $P(B)=0.7$ . Tính $P(A \cap B)$ và chứng tỏ $A$ và $B$ độc lập với nhau. | Tính xác suất của biến cố | CD01_01  | Bank        | Text                      | None           | /buoc1 Sử dụng công thức cộng xác suất: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ .<br>/buoc2 Thay số: $P(A \cup B) = 0.6 + 0.7 - 0.88 = 0.42$ .<br>/buoc3 Xét tích xác suất: $P(A) \cdot P(B) = 0.6 \cdot 0.7 = 0.42$ .<br>/ketluan Vì $P(A \cup B) = P(A) \cdot P(B) = 0.42$ nên $A$ và $B$ độc lập với nhau.<br>/dapan độc lập | $A$ và $B$ độc lập. |
| 2  | Hãy giải giúp tôi bài sau: | Cho hai biến cố A và B. Biết rằng $P(A+B)=0.6$ ; $P(A)=0.5$ ; $P(B)=0.2$ . Tính $P(A \cap B)$ và chứng tỏ A và B độc lập với nhau. | Cho hai biến cố $A$ và $B$ . Biết rằng $P(A \cup B)=0.6$ ; $P(A)=0.5$ ; $P(B)=0.2$ . Tính $P(A \cap B)$ và chứng tỏ $A$ và $B$ độc lập với nhau.  | Tính xác suất của biến cố | CD01_01  | Bank        | Text                      | None           | /buoc1 Sử dụng công thức cộng xác suất: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ .<br>/buoc2 Thay số: $P(A \cup B) = 0.5 + 0.2 - 0.6 = 0.1$ .<br>/buoc3 Xét tích xác suất: $P(A) \cdot P(B) = 0.5 \cdot 0.2 = 0.1$ .<br>/ketluan Vì $P(A \cup B) = P(A) \cdot P(B) = 0.1$ nên $A$ và $B$ độc lập với nhau.<br>/dapan độc lập     | $A$ và $B$ độc lập. |

Hình 2. 1. Minh họa bộ dữ liệu sau khi tiền xử lý

Bộ dữ liệu ban đầu gồm 785 câu hỏi thuộc 5 chủ đề của Xác suất – Thống kê. Nhằm gia tăng số lượng và độ đa dạng của dữ liệu huấn luyện, em đã áp dụng kỹ thuật tăng cường dữ liệu (*Data Augmentation*) với sự hỗ trợ của các mô hình ngôn ngữ lớn như ChatGPT và Gemini. Các phương pháp tăng cường chủ yếu bao gồm:

- Thay thế số liệu trong đề bài trong khi giữ nguyên dạng toán.

- Diễn đạt lại nội dung câu hỏi bằng các cách biểu đạt ngôn ngữ khác nhau nhưng bảo toàn ý nghĩa.
- Tạo lời giải mẫu chi tiết tương ứng cho từng biến thể mới.

Quá trình này giúp mở rộng dữ liệu cả về nội dung số liệu lẫn hình thức diễn đạt, đồng thời vẫn duy trì tính nhất quán về mặt kiến thức. Sau quá trình lọc trùng, kiểm tra tính đúng đắn và chuẩn hóa định dạng, bộ dữ liệu cuối cùng thu được 5.360 mẫu bài toán Xác suất – Thống kê, được tổ chức theo định dạng *instruction–input–output*.

Bảng 2. 1. Phân bố dữ liệu theo nhóm chủ đề


| STT              | Nhóm chủ đề                              | Số lượng mẫu | Tỷ lệ (%)   |
|------------------|------------------------------------------|--------------|-------------|
| 1                | Tính xác suất của biến cố                | 1,072        | 20%         |
| 2                | Biến ngẫu nhiên và các đặc trưng         | 1,072        | 20%         |
| 3                | Quy luật phân phối xác suất              | 1,340        | 25%         |
| 4                | Thống kê cơ bản (Ước lượng và kiểm định) | 1,072        | 20%         |
| 5                | Phân tích tương quan và hồi quy          | 804          | 15%         |
| <b>Tổng cộng</b> |                                          | <b>5.360</b> | <b>100%</b> |

Để tối ưu hóa khả năng đọc hiểu ngữ cảnh toán học của LLM, mỗi điểm dữ liệu được thiết kế thành một bản ghi CSV với ba trường thông tin cốt lõi:

- **Instruction (Câu hỏi):** Nội dung đề bài XSTK chi tiết bằng ngôn ngữ tự nhiên tiếng Việt, mô tả đầy đủ bối cảnh, giả thiết và mục tiêu bài toán.

- **LaTeX Input (Dữ kiện toán học đầu vào):** Các biểu thức và tham số toán học quan trọng được trích xuất từ đề bài và chuyển sang định dạng LaTeX chuẩn hóa. Ví dụ:  $P(A \cup B)$ ,  $P(A \cap B)$ ,  $\mu = 5$ ,  $\sigma^2 = 2$ . Trường này đóng vai trò như một tín hiệu ngữ cảnh (contextual hint), giúp mô hình tập trung vào các đại lượng và công thức cốt lõi trước khi suy luận.

- **Response (Lời giải chuẩn):** Lời giải chi tiết tuân thủ nghiêm ngặt tư duy chuỗi (Step-by-step reasoning), trải dài từ phân tích biến, áp dụng định lý, tính toán trung gian cho đến kết luận cuối cùng.



Hình 2. 2. Quy trình thu thập và xây dựng tập dữ liệu XSTK

### 2.1.2. Làm sạch dữ liệu và thiết kế cấu trúc Prompt

Sau giai đoạn thu thập và xây dựng dữ liệu ban đầu, bộ dữ liệu tiếp tục được làm sạch và chuẩn hóa trước khi đưa vào quá trình huấn luyện. Đây là bước quan trọng nhằm bảo đảm rằng dữ liệu đầu vào có chất lượng đủ tốt, hạn chế tối đa các lỗi hình thức có thể ảnh hưởng đến khả năng học của mô hình. Đối với bài toán giải Xác suất – Thống kê, việc làm sạch dữ liệu không chỉ dừng ở xử lý văn bản thông thường mà còn phải chú ý đến tính chính xác của biểu thức toán học và sự nhất quán trong cấu trúc lời giải.

Quy trình làm sạch dữ liệu trong nghiên cứu này tập trung vào ba nội dung chính.

- **Rà soát và làm sạch dữ liệu thô:** Toàn bộ hơn 5.300 mẫu dữ liệu được kiểm tra lại để bảo đảm không có trường thông tin quan trọng nào bị bỏ trống, đặc biệt là phần đề bài và phần lời giải. Những cột không phục vụ trực tiếp cho quá trình huấn luyện cũng được loại bỏ nhằm làm cho bộ dữ liệu gọn hơn và dễ xử lý hơn trong các bước tiếp theo. Việc rà soát này giúp hạn chế tình trạng mô hình nhận dữ liệu thiếu hoặc không đồng nhất giữa các mẫu.

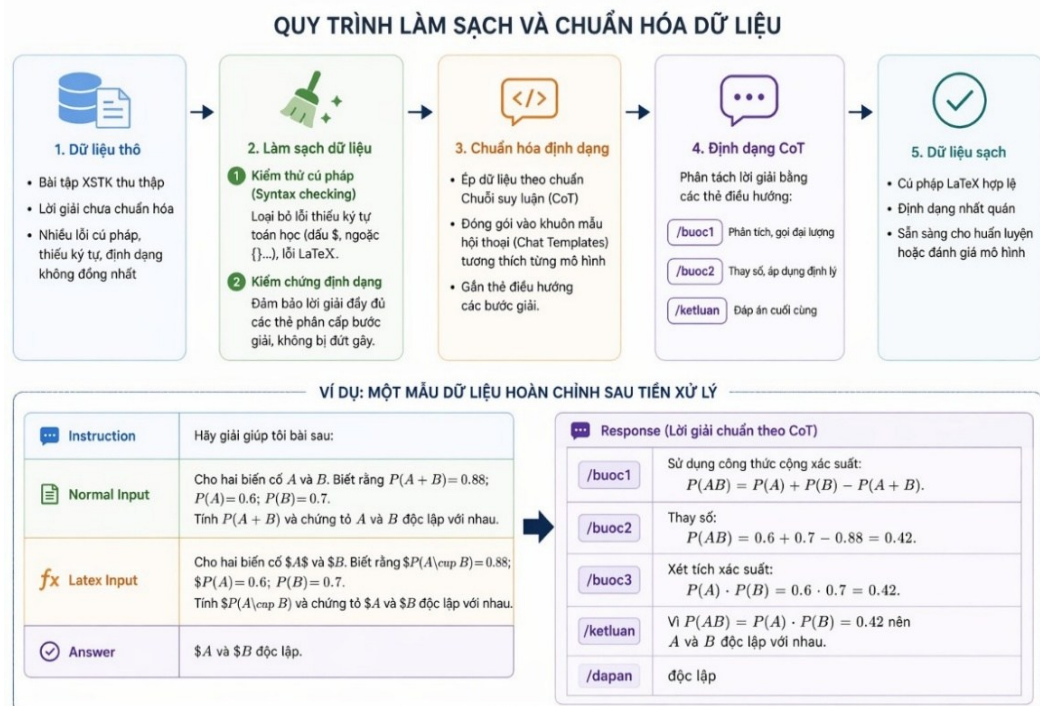
- **Kiểm tra cú pháp LaTeX:** Vì bộ dữ liệu có chứa nhiều công thức và ký hiệu toán học, việc kiểm tra cú pháp LaTeX được thực hiện cẩn thận để phát hiện các lỗi thường gặp như thiếu dấu \$, sai ngoặc {}, ký hiệu không khớp hoặc biểu thức viết chưa đúng chuẩn. Mục tiêu của bước này là bảo đảm rằng các công thức trong dữ liệu đều có thể hiển thị và được hiểu đúng, từ đó giúp mô hình học ổn định hơn trên các biểu thức toán học.



- **Kiểm tra tính nhất quán của cấu trúc lời giải:** Toàn bộ phần lời giải được đối chiếu lại để bảo đảm các mẫu đều tuân thủ cùng một cấu trúc trình bày. Cụ thể, lời giải cần được tổ chức theo hướng suy luận từng bước và có đầy đủ các thành phần cần thiết, tránh tình trạng thiếu thớt, sai thứ tự hoặc trình bày không thống nhất giữa các mẫu. Bước này đặc biệt quan trọng vì đề tài không chỉ hướng tới việc mô hình đưa ra đáp án đúng, mà còn yêu cầu mô hình sinh được lời giải có cấu trúc rõ ràng và dễ đánh giá.

Sau khi hoàn thành bước làm sạch, dữ liệu được chuẩn hóa theo cấu trúc Prompt dạng hội thoại (*Chat Template*) để phù hợp hơn với cách tiếp nhận dữ liệu của các mô hình ngôn ngữ lớn. Trong cấu trúc này, mỗi lời giải được phân tách rõ ràng bằng các thẻ điều hướng như `/buoc1`, `/buoc2`, `/ketluan` và `/dapan`. Cách tổ chức này giúp mô hình học được trình tự giải bài theo từng bước, đồng thời hỗ trợ quá trình đánh giá đầu ra ở giai đoạn sau.

Việc chuẩn hóa Prompt theo cấu trúc thống nhất cũng giúp giảm sự khác biệt hình thức giữa các mẫu dữ liệu, qua đó làm cho quá trình huấn luyện ổn định hơn. Đồng thời, đây cũng là cơ sở để mô hình sinh ra lời giải có bố cục rõ ràng, phù hợp với mục tiêu của đề tài là không chỉ trả lời đúng mà còn giải thích được cách làm.



Hình 2. 3. Quy trình làm sạch và chuẩn hóa dữ liệu

## 2.2. THIẾT KẾ KIẾN TRÚC MÔ HÌNH

### 2.2.1. Lựa chọn phiên bản cụ thể của Gemma và Qwen

Trong phạm vi nghiên cứu này, việc lựa chọn mô hình nền được thực hiện trên cơ sở cân đối giữa hai yêu cầu: thứ nhất là khả năng xử lý các bài toán có yếu tố suy luận toán học; thứ hai là tính khả thi khi triển khai huấn luyện trong điều kiện phần cứng giới hạn. Với môi trường thực nghiệm sử dụng GPU NVIDIA T4 16GB, nghiên cứu tập trung vào các mô hình thuộc phân khúc khoảng 7 tỷ tham số, vì đây là mức dung lượng phù hợp để có thể fine-tune bằng QLoRA mà vẫn bảo đảm chất lượng mô hình.

Trên cơ sở đó, hai mô hình được lựa chọn là **Google/Gemma-7b-it** và **Qwen/Qwen2.5-Math-7B-Instruct**. Việc lựa chọn hai mô hình này không chỉ nhằm mục đích huấn luyện và đánh giá riêng lẻ, mà còn để thực hiện đối sánh giữa hai hướng tiếp cận khác nhau: một mô hình ngôn ngữ tổng quát đã được tinh chỉnh theo chỉ lệnh, và một mô hình được phát triển theo định hướng chuyên biệt cho toán học.

- **Google/Gemma-7b-it**: Đây là phiên bản 7B đã được tinh chỉnh theo chỉ lệnh của Google. Mô hình này thuộc nhóm mô hình ngôn ngữ tổng quát, có khả năng xử lý ngôn ngữ tự nhiên linh hoạt và phù hợp với các tác vụ hỏi đáp, giải thích hoặc sinh văn bản có cấu trúc. Trong bối cảnh của đề tài, Gemma-7b-it được lựa chọn nhằm đánh giá khả năng thích nghi của một mô hình đa dụng khi được fine-tune trên dữ liệu Xác suất – Thống kê bằng tiếng Việt. Ngoài ra, mô hình cũng có ưu điểm là có thể vận hành tương đối ổn định trên GPU phổ thông khi kết hợp với kỹ thuật lượng tử hóa.

- **Qwen/Qwen2.5-Math-7B-Instruct**: Đây là phiên bản 7B chuyên biệt cho toán học trong dòng Qwen2.5-Math của Alibaba Cloud. So với các mô hình tổng quát, Qwen2.5-Math được thiết kế theo định hướng phù hợp hơn với các bài toán yêu cầu suy luận nhiều bước, xử lý biểu thức toán học và nhận diện ký hiệu LaTeX. Trong nghiên cứu này, mô hình được lựa chọn để kiểm tra mức độ hiệu quả của một mô hình có nền tảng toán học tốt hơn khi áp dụng vào bài toán giải Xác suất – Thống kê bằng tiếng Việt.

Một điểm chung của cả hai mô hình là đều được nạp vào bộ nhớ dưới định dạng lượng tử hóa 4-bit NF4 thông qua thư viện bitsandbytes. Việc lượng tử hóa này giúp giảm đáng kể yêu cầu bộ nhớ GPU, từ đó cho phép triển khai fine-tuning trên phần cứng ở mức phổ thông như NVIDIA T4 16GB. Tuy nhiên,

để bảo đảm độ ổn định trong quá trình huấn luyện, các phép tính ma trận ở bước lan truyền xuôi và lan truyền ngược vẫn được thực hiện ở chuẩn bfloat16. Cách thiết lập này giúp cân bằng giữa yêu cầu tiết kiệm tài nguyên và yêu cầu ổn định số học trong quá trình tối ưu mô hình.

Việc lựa chọn hai mô hình nêu trên vì vậy vừa phù hợp với điều kiện thực nghiệm của đề tài, vừa tạo ra cơ sở hợp lý để so sánh giữa một mô hình ngôn ngữ tổng quát và một mô hình có định hướng chuyên biệt cho toán học. Kết quả đối sánh giữa hai mô hình sẽ được sử dụng để làm rõ hơn mức độ ảnh hưởng của kiến trúc nền và dữ liệu tiền huấn luyện đối với bài toán giải Xác suất – Thống kê bằng tiếng Việt.

#### *Minh họa khởi tạo mô hình*

Để triển khai quá trình fine-tuning, mô hình được khởi tạo thông qua thư viện transformers, đồng thời cấu hình lượng tử hóa 4-bit được thiết lập bằng BitsAndBytesConfig. Trong đoạn mã dưới đây, mô hình google/gemma-7b-it được nạp cùng tokenizer tương ứng, với các tham số lượng tử hóa phù hợp cho QLoRA:

```
from transformers import AutoTokenizer,
AutoModelForCausalLM, BitsAndBytesConfig
import torch
model_id = "google/gemma-7b-it"
bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.bfloat16,
    bnb_4bit_use_double_quant=True,
)
tokenizer = AutoTokenizer.from_pretrained(model_id)
tokenizer.pad_token = tokenizer.eos_token
tokenizer.padding_side = "right"
model = AutoModelForCausalLM.from_pretrained(
    model_id,
```

```
quantization_config=bnb_config,
device_map="auto",
torch_dtype=torch.bfloat16,
)
```

Trong đoạn mã, tham số `load_in_4bit=True` cho phép mô hình được nạp dưới dạng lượng tử hóa 4-bit; `bnb_4bit_quant_type="nf4"` xác định chuẩn lượng tử hóa NF4; còn `bnb_4bit_compute_dtype=torch.bfloat16` cho biết các phép tính trong quá trình huấn luyện vẫn được thực hiện ở chuẩn `bfloat16`. Thiết lập này phù hợp với cách tiếp cận QLoRA mà đề tài sử dụng.

Đối với mô hình Qwen2.5-Math-7B-Instruct, quy trình khởi tạo được thực hiện tương tự, chỉ thay đổi giá trị của `model_id` tương ứng với mô hình cần sử dụng. Điều này giúp bảo đảm tính nhất quán trong quá trình triển khai, đồng thời tạo điều kiện thuận lợi cho việc so sánh giữa hai mô hình trong cùng một môi trường thực nghiệm.

### 2.2.2. Thiết lập siêu tham số cho cấu hình QLoRA

Phương pháp QLoRA đóng băng trọng số mô hình gốc và chỉ huấn luyện các ma trận phân rã hạng thấp (adapter) được chèn vào mạng Attention. Cấu hình siêu tham số được chia làm ba nhóm và áp dụng nhất quán cho cả hai mô hình.

#### 2.2.2.1. Nhóm siêu tham số lượng tử hóa (BitsAndBytes)

Bảng 2. 2. Cấu hình siêu tham số lượng tử hóa BitsAndBytes

| Siêu tham số                           | Giá trị               | Lý do lựa chọn                                                               |
|----------------------------------------|-----------------------|------------------------------------------------------------------------------|
| <code>load_in_4bit</code>              | TRUE                  | Nén trọng số từ 16-bit xuống 4-bit để giảm mạnh VRAM.                        |
| <code>bnb_4bit_quant_type</code>       | "nf4"                 | Định dạng NF4 tối ưu nhất về lý thuyết thông tin cho phân phối trọng số LLM. |
| <code>bnb_4bit_compute_dtype</code>    | <code>bfloat16</code> | Tính toán vẫn ở 16-bit để đảm bảo độ chính xác và ổn định gradient.          |
| <code>bnb_4bit_use_double_quant</code> | TRUE                  | Lượng tử hóa kép giúp khai thác tối đa không gian VRAM còn lại.              |

#### 2.2.2.2. Nhóm siêu tham số LoRA

Bảng 2. 3. Cấu hình siêu tham số LoRA Adapter

| Siêu tham số            | Giá trị    | Mô tả                                                                                            |
|-------------------------|------------|--------------------------------------------------------------------------------------------------|
| LoRA Rank ( $r$ )       | 16         | Chiều ảm của ma trận cập nhật; cân bằng giữa khả năng học tri thức mới và ngăn chặn Overfitting. |
| LoRA Alpha ( $\alpha$ ) | 32         | Hệ số tỷ lệ tác động của LoRA ( $\alpha = 2r$ ).                                                 |
| Target Modules          | All Linear | Áp dụng LoRA cho toàn bộ các ma trận chiều (q, k, v, o, gate, up, down_proj).                    |
| LoRA Dropout            | 0,05       | Tỷ lệ dropout nhẹ để tăng tính tổng quát hóa.                                                    |
| Task Type               | CAUSAL_LM  | Tác vụ sinh văn bản tự hồi quy (Decoder-only).                                                   |

#### 2.2.2.3. Nhóm siêu tham số huấn luyện (SFTTrainer)

Bảng 2. 4. Cấu hình siêu tham số huấn luyện SFTTrainer

| Siêu tham số                | Giá trị              |
|-----------------------------|----------------------|
| Learning Rate               | $2,0 \times 10^{-4}$ |
| Batch Size vật lý           | 2                    |
| Gradient Accumulation Steps | 4                    |
| Effective Batch Size        | 8                    |
| Số Epoch                    | 1                    |
| Max Sequence Length         | 2,048 token          |
| Optimizer                   | paged_adamw_32bit    |
| LR Scheduler                | cosine               |
| Warmup Ratio                | 0,03                 |

**Lý giải cho các quyết định siêu tham số:**

- **Learning Rate và Cosine Annealing:** Tốc độ học  $2 \times 10^{-4}$  giúp mô hình thích nghi nhanh ở giai đoạn đầu. Sau đó, tốc độ giảm dần theo hàm cosine để hội tụ ổn định mà không gây hiện tượng quên thảm khốc (Catastrophic Forgetting) tri thức nền.

- **Chiến lược Batch Size:** Kết hợp Batch Size vật lý bằng 2 và Gradient Accumulation bằng 4 tạo ra Effective Batch Size bằng 8, đảm bảo ổn định cập nhật gradient trong giới hạn 16GB VRAM.

- **Epoch = 1:** Với 5.360 mẫu dữ liệu chất lượng cao, 1 epoch là ngưỡng tối ưu để mô hình học tư duy giải toán mà không rơi vào trạng thái học vẹt đáp án.

*Minh họa cấu hình siêu tham số*

```
import torch
from transformers import BitsAndBytesConfig,
TrainingArguments
from peft import LoraConfig

# 1. Cấu hình lượng tử hóa 4-bit
bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.bfloat16,
    bnb_4bit_use_double_quant=True,
)

# 2. Cấu hình LoRA
lora_config = LoraConfig(
    r=16,
    lora_alpha=32,
    lora_dropout=0.05,
    bias="none",
    task_type="CAUSAL_LM",
```

```

        target_modules=[
            "q_proj", "k_proj", "v_proj", "o_proj",
            "gate_proj", "up_proj", "down_proj"
        ],
    )

# 3. Cấu hình huấn luyện
training_args = TrainingArguments(
    output_dir="./output",
    per_device_train_batch_size=2,
    gradient_accumulation_steps=4,
    learning_rate=2e-4,
    num_train_epochs=1,
    lr_scheduler_type="cosine",
    warmup_ratio=0.03,
    optim="paged_adamw_32bit",
    bf16=True,
    logging_steps=10,
    save_strategy="epoch",
    report_to="none",
)

```

## 2.3. LẬP KẾ HOẠCH TRIỂN KHAI

### 2.3.1. Lựa chọn công cụ và môi trường huấn luyện

Toàn bộ quá trình từ tiền xử lý dữ liệu, huấn luyện mô hình đến đánh giá được triển khai trên môi trường điện toán đám mây nhằm đảm bảo tính ổn định và khả năng tái lập thí nghiệm.

#### 2.3.1.1. Môi trường tính toán

**Nền tảng:** Google Colab Pro – môi trường máy chủ linh hoạt, phù hợp với quy mô nghiên cứu học thuật.

**Phần cứng:** GPU NVIDIA T4, đủ điều kiện chạy thuật toán QLoRA cho các LLM 7 tỷ tham số với hiệu suất cao.

**Phần mềm:** Python 3.11 kết hợp hệ sinh thái PyTorch.

#### 2.3.1.2. Hệ sinh thái thư viện lỗi

Bảng 2. 5. Hệ sinh thái thư viện sử dụng trong nghiên cứu

| Thư viện         | Phiên bản | Vai trò                                                      |
|------------------|-----------|--------------------------------------------------------------|
| Transformers     | 5.0.0     | Tải trọng số, quản lý kiến trúc mạng, thực thi suy luận.     |
| PEFT             | 0.10+     | Tích hợp các module adapter LoRA/QLoRA vào mô hình nền.      |
| BitsAndBytes     | 0.43+     | Thực hiện lượng tử hóa 4-bit (NF4) để nén trọng số.          |
| TRL (SFTTrainer) | 0.8+      | Quản lý vòng lặp SFT, tính hàm mất mát và cập nhật gradient. |
| Pandas/NumPy     | Mới nhất  | Tiền xử lý dữ liệu và thống kê số liệu thực nghiệm.          |

#### 2.3.1.3. Hệ thống đánh giá (Evaluation Pipeline)

Nghiên cứu xây dựng pipeline đánh giá tự động hai lớp:

- **Lớp 1 – Hard Metric:** Mã Python tự động trích xuất số liệu từ thẻ /ketluan và so sánh với đáp án chuẩn với ngưỡng sai số cho phép  $\pm 0,01$ . Đây là bộ lọc đánh giá nhị phân (Đúng/Sai) cho toàn bộ tập Test.

- **Lớp 2 – LLM-as-a-Judge:** Với các mẫu cần đánh giá chuyên sâu, hệ thống gọi API của các LLM tiên tiến (Gemini hoặc GPT-4o) đóng vai trò Giám khảo, chấm điểm theo ba tiêu chí: tính đúng đắn toán học (Math), chất lượng lập luận (Logic) và chuẩn mực định dạng (Formatting).

#### 2.3.2. Quy trình thực hiện

Quy trình thực hiện khóa luận được tổ chức thành bốn giai đoạn liên tiếp, tạo thành một quy trình nghiên cứu tương đối hoàn chỉnh từ bước xây dựng dữ liệu, tinh chỉnh mô hình cho đến đánh giá kết quả đầu ra. Việc phân chia thành



các giai đoạn riêng giúp quá trình triển khai rõ ràng hơn, đồng thời thuận lợi cho việc theo dõi, kiểm soát và phân tích kết quả ở từng bước.

- **Giai đoạn 1 – Xây dựng và chuẩn bị dữ liệu:** Ở giai đoạn đầu, em tiếp nhận các bài toán mẫu thuộc học phần Xác suất – Thống kê, sau đó tiến hành giải chi tiết và số hóa thủ công để tạo thành bộ dữ liệu phục vụ huấn luyện. Mỗi mẫu dữ liệu được tổ chức theo ba thành phần chính gồm *Instruction*, *LaTeX Input* và *Response*. Trong đó, *Instruction* mô tả yêu cầu bài toán bằng tiếng Việt, *LaTeX Input* biểu diễn các dữ kiện và công thức toán học dưới dạng chuẩn hóa, còn *Response* là lời giải chi tiết theo từng bước. Sau khi biên soạn, dữ liệu được kiểm tra cú pháp LaTeX, rà soát lỗi định dạng và đánh giá tính nhất quán của các thẻ suy luận theo cấu trúc Chain-of-Thought. Cuối cùng, bộ dữ liệu được chia thành tập huấn luyện và tập đánh giá nội bộ theo tỷ lệ 90% và 10%, tương ứng với 4.824 mẫu huấn luyện và 536 mẫu đánh giá, bằng phương pháp lấy mẫu phân tầng để bảo đảm sự cân bằng giữa các nhóm chủ đề. Bên cạnh đó, một bộ kiểm tra độc lập gồm hơn 300 mẫu cũng được chuẩn bị riêng để sử dụng trong bước đánh giá cuối cùng.

- **Giai đoạn 2 – Tinh chỉnh mô hình:** Trên cơ sở bộ dữ liệu đã được chuẩn hóa, em tự thiết lập môi trường thực nghiệm bằng Python cùng các thư viện học sâu phù hợp cho bài toán fine-tuning mô hình ngôn ngữ lớn. Hai mô hình nền được lựa chọn là Gemma-7B-it và Qwen2.5-Math-7B. Các mô hình này được nạp ở định dạng lượng tử hóa 4-bit để giảm yêu cầu bộ nhớ, đồng thời tích hợp adapter theo kỹ thuật QLoRA nhằm thực hiện tinh chỉnh tham số hiệu quả. Sau bước khởi tạo cấu hình, quá trình huấn luyện có giám sát (Supervised Fine-Tuning – SFT) được thực hiện trên cùng một bộ dữ liệu cho cả hai mô hình để bảo đảm tính công bằng khi so sánh. Trong suốt quá trình huấn luyện, các chỉ số như Training Loss và Validation Loss được theo dõi liên tục nhằm quan sát mức độ hội tụ, phát hiện sớm hiện tượng dao động mạnh hoặc quá khớp, từ đó đánh giá khả năng thích nghi của từng mô hình đối với dữ liệu Xác suất – Thống kê bằng tiếng Việt.

- **Giai đoạn 3 – Kiểm thử và sinh kết quả:** Sau khi hoàn tất quá trình tinh chỉnh, các mô hình được đưa vào giai đoạn suy luận trên tập kiểm tra độc lập. Ở bước này, em sử dụng chiến lược giải mã tham lam (Greedy Decoding) với tham số temperature = 0 nhằm hạn chế yếu tố ngẫu nhiên trong quá trình sinh câu trả lời, qua đó giúp kết quả phản ánh rõ hơn năng lực thực tế của mô hình. Toàn bộ quá trình kiểm thử được thực hiện trên khoảng 350 mẫu thuộc tập

Test, bao phủ các nhóm chủ đề đã xây dựng trước đó. Đầu ra của mô hình không chỉ bao gồm đáp án cuối cùng mà còn bao gồm toàn bộ chuỗi suy luận trung gian, tạo cơ sở thuận lợi cho việc đánh giá chất lượng lời giải ở bước tiếp theo.

- **Giai đoạn 4 – Đánh giá và so sánh kết quả:** Trong giai đoạn cuối, em tiến hành trích xuất và tổng hợp toàn bộ kết quả sinh ra từ hai mô hình để phục vụ đánh giá. Việc đánh giá được triển khai theo hai hướng song song. Thứ nhất, em sử dụng các chỉ số định lượng dạng *Hard Metric* để xác định mức độ chính xác của đáp án cuối, từ đó tính toán tỷ lệ trả lời đúng trên toàn bộ tập kiểm tra cũng như trên từng nhóm chủ đề. Thứ hai, phương pháp *LLM-as-a-Judge* được áp dụng để đánh giá sâu hơn chất lượng lời giải theo các tiêu chí như tính logic, độ chính xác toán học và mức độ đầy đủ của cấu trúc trình bày. Trên cơ sở đó, nghiên cứu không chỉ dừng lại ở việc so sánh hai mô hình theo tỷ lệ đúng sai, mà còn mở rộng sang phân tích định tính, bao gồm việc nhận diện các dạng lỗi điển hình, đánh giá điểm mạnh và điểm yếu của từng kiến trúc, cũng như làm rõ sự khác biệt giữa mô hình đa dụng và mô hình chuyên biệt cho toán học.

## CHƯƠNG 3: TRIỂN KHAI KỸ THUẬT VÀ PHÂN TÍCH THỰC NGHIỆM

Chương này mô tả chi tiết quy trình triển khai kỹ thuật từ thiết lập môi trường, cấu hình mô hình đến quá trình tinh chỉnh, đồng thời trình bày các kết quả thực nghiệm và phân tích so sánh hiệu suất giữa hai kiến trúc mô hình. Toàn bộ quy trình triển khai kỹ thuật từ thiết lập môi trường, cấu hình mô hình đến quá trình tinh chỉnh đều được thực hiện và lưu trữ công khai tại: [https://github.com/Ldtug0105/LLMs\\_for\\_Probability-Statistics](https://github.com/Ldtug0105/LLMs_for_Probability-Statistics)

### 3.1. TRIỂN KHAI KỸ THUẬT

#### 3.1.1. Cấu hình môi trường và nền tảng tính toán

Quá trình thực nghiệm được triển khai trên Google Colab và Kaggle Notebook nhằm tận dụng tài nguyên phần cứng được cấp phát và đảm bảo khả năng tái lập (reproducibility). Hệ thống được trang bị **GPU NVIDIA T4** với **16GB VRAM**, đáp ứng tốt nhu cầu tính toán cho các mô hình 7 tỷ tham số khi kết hợp lượng tử hóa bộ nhớ. Môi trường phát triển được chuẩn hóa với Python 3.11 và hệ sinh thái PyTorch.

Các thư viện lõi phục vụ triển khai bao gồm:

- **Transformers:** Tải trọng số, quản lý cấu trúc mạng và thực thi suy luận.
- **PEFT:** Khung làm việc hỗ trợ tích hợp các module tinh chỉnh tham số hiệu quả như LoRA và QLoRA.
- **BitsAndBytes:** Thực hiện lượng tử hóa trọng số xuống chuẩn 4-bit.
- **Unsloth:** Thư viện tối ưu hóa chuyên biệt giúp tăng tốc lan truyền ngược và tối giản VRAM tiêu thụ trong quá trình huấn luyện.

#### 3.1.2. Cấu hình siêu tham số huấn luyện

Để đảm bảo tính khách quan trong đối sánh, cả hai kiến trúc mô hình được thiết lập với cùng bộ siêu tham số huấn luyện thống nhất, được trình bày tại Bảng 3.1.

Bảng 3. 1. Siêu tham số huấn luyện áp dụng cho hai mô hình

| Siêu tham số            | Gemma-7B-it | Qwen2.5-Math-7B |
|-------------------------|-------------|-----------------|
| LoRA rank ( $r$ )       | 16          | 16              |
| LoRA alpha ( $\alpha$ ) | 32          | 32              |

|                        |                      |                      |
|------------------------|----------------------|----------------------|
| Learning rate          | $2,0 \times 10^{-4}$ | $2,0 \times 10^{-4}$ |
| Batch size vật lý      | 2                    | 2                    |
| Gradient Accumulation  | 4 bước               | 4 bước               |
| Effective Batch size   | 8                    | 8                    |
| Số Epoch               | 1                    | 1                    |
| Optimizer              | paged_adamw_32bit    | paged_adamw_32bit    |
| Chuẩn lượng tử hóa     | 4-bit (NF4)          | 4-bit (NF4)          |
| LR Scheduler           | cosine               | cosine               |
| Cửa sổ ngữ cảnh tối đa | 2,048 token          | 2,048 token          |

### 3.1.3. Quá trình huấn luyện

Tiến trình huấn luyện được thiết kế theo quy trình khép kín gồm bốn giai đoạn:

- **Xây dựng và tiền xử lý ngữ liệu:** Bộ dữ liệu 5.360 mẫu được tổ chức theo định dạng CSV, với mỗi bản ghi gồm ba thành phần: Instruction (câu lệnh tiếng Việt), LaTeX Input (biểu diễn LaTeX) và Response (lời giải phân rã theo thẻ CoT). Cấu trúc này buộc LLM hình thành chuỗi suy luận nội tại trước khi đưa ra đáp án.


- **Tinh chỉnh có giám sát (SFT):** Mô hình tối ưu hóa hàm mất mát Cross-Entropy dựa trên độ lệch giữa văn bản sinh ra và nhãn thực tế. Qua chu kỳ cập nhật trọng số, mô hình tiếp thu ba năng lực: phân tích ngữ nghĩa tiếng Việt, vận dụng định lý thống kê và sinh văn bản theo cấu trúc CoT.

- **Tối ưu hóa tham số với QLoRA:** Đóng băng toàn bộ trọng số nền ở định dạng 4-bit (NF4) và chỉ cập nhật gradient trên các LoRA adapter tại các phân lớp Attention (q, k, v, o\_proj) và FFN. Kỹ thuật này giảm khoảng 70% lượng VRAM tiêu thụ so với Full Fine-tuning nhưng vẫn bảo toàn hiệu suất ở mức xấp xỉ.


- **Suy luận và kiểm định:** Giai đoạn kiểm định trên tập Test sử dụng chiến lược Greedy Decoding (temperature = 0) để loại bỏ yếu tố ngẫu nhiên, đảm bảo tính ổn định và khả năng tái lập cao nhất.

## 3.2. KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

### 3.2.1. Đánh giá quá trình huấn luyện (Training Loss)



Hình 3. 1. Qwen 2.5 Math Training loss



Hình 3. 2. Gemma 7b Training loss

Quan sát đồ thị Training Loss cho thấy cả hai mô hình đều có xu hướng hội tụ tốt sau quá trình fine-tuning. Ở giai đoạn đầu huấn luyện, giá trị loss giảm rất nhanh, phản ánh việc mô hình nhanh chóng thích nghi với cấu trúc dữ liệu mới và học được các mẫu suy luận cơ bản trong bộ dữ liệu Xác suất – Thống kê. Sau giai đoạn giảm mạnh ban đầu, đường loss tiếp tục giảm chậm hơn và dần ổn định về cuối quá trình huấn luyện, cho thấy mô hình đã tiến tới trạng thái hội tụ.

Đối với Gemma-7B-it, giá trị training loss ban đầu ở mức khá cao, trên 4.0, sau đó giảm nhanh xuống dưới 1.0 chỉ sau một số bước huấn luyện đầu tiên. Về cuối quá trình, loss ổn định quanh mức xấp xỉ 0.22. Đường cong giảm khá mượt, dao động nhỏ và không xuất hiện hiện tượng tăng ngược kéo dài, cho thấy quá trình tối ưu diễn ra ổn định. Tuy nhiên, mức loss khởi điểm cao hơn

cho thấy mô hình cần nhiều điều chỉnh hơn để thích nghi với dữ liệu chuyên biệt.

Trong khi đó, Qwen2.5-Math có giá trị training loss ban đầu thấp hơn, khoảng 1.1, và giảm dần xuống khoảng 0.14 ở cuối quá trình huấn luyện. So với Gemma-7B-it, đường loss của Qwen2.5-Math nhìn chung thấp hơn trong toàn bộ quá trình và đạt mức cuối nhỏ hơn, cho thấy mô hình này thích nghi tốt hơn với bài toán. Điều này là hợp lý vì Qwen2.5-Math vốn là mô hình có định hướng toán học, nên có lợi thế hơn khi xử lý các bài toán yêu cầu suy luận và tính toán.

Nhìn chung, cả hai mô hình đều không xuất hiện dấu hiệu bất thường như loss dao động mạnh hoặc không giảm, do đó có thể kết luận rằng cấu hình fine-tuning được lựa chọn là phù hợp. Tuy nhiên, Qwen2.5-Math cho thấy quá trình hội tụ nhanh hơn và ổn định hơn, đồng thời đạt mức training loss thấp hơn Gemma-7B-it. Kết quả này phù hợp với các đánh giá ở giai đoạn kiểm thử, khi Qwen2.5-Math sau fine-tuning cũng cho hiệu năng tốt hơn trên tập dữ liệu Xác suất – Thống kê.

### 3.2.2. Đánh giá khả năng giải toán trên tập Test

Sau khi hoàn tất quá trình huấn luyện, hai mô hình được đánh giá trên một tập kiểm tra độc lập gồm hơn 300 câu hỏi, bao phủ 5 nhóm chủ đề chính của học phần Xác suất – Thống kê. Việc sử dụng tập kiểm tra tách biệt với tập huấn luyện và tập đánh giá nội bộ giúp phản ánh khách quan hơn năng lực thực tế của mô hình sau fine-tuning.

#### Kết quả tổng quan

Kết quả thực nghiệm cho thấy cả hai mô hình đều cải thiện đáng kể sau khi được tinh chỉnh trên bộ dữ liệu chuyên biệt.

- **Qwen2.5-Math:** Độ chính xác trung bình tăng từ 36,67% ở phiên bản gốc lên 72,46% ở phiên bản sau tinh chỉnh, tương ứng mức tăng 35,79%.
- **Gemma-7B-it:** Từ mức khởi đầu 10,00%, mô hình đạt 54,20% sau tinh chỉnh, tương ứng mức tăng 44,20 %.

Kết quả này cho thấy quá trình fine-tuning đã giúp cả hai mô hình thích nghi tốt hơn với bài toán giải Xác suất – Thống kê bằng tiếng Việt. Đồng thời, điều đó cũng phản ánh vai trò tích cực của bộ dữ liệu huấn luyện và cấu trúc lời giải từng bước trong việc cải thiện chất lượng đầu ra.

Để làm rõ hơn sự khác biệt về năng lực giữa các mô hình, nghiên cứu tiếp tục phân tích độ chính xác theo từng nhóm chủ đề. Kết quả được tổng hợp trong Bảng 3.2

Bảng 3. 2. Tỷ lệ chính xác (%) theo nhóm chủ đề – so sánh mô hình gốc và sau tinh chỉnh

| Chủ đề                           | Qwen (gốc)    | Qwen (FT)     | Gemma (gốc)   | Gemma (FT)    |
|----------------------------------|---------------|---------------|---------------|---------------|
| Tính xác suất của biến cố        | 90,00%        | 95,00%        | 11,11%        | 73,00%        |
| Biến ngẫu nhiên và các đặc trưng | 16,67%        | 60,00%        | 1,67%         | 41,67%        |
| Quy luật phân phối xác suất      | 13,64%        | 89,86%        | 34,09%        | 76,81%        |
| Ước lượng và kiểm định thống kê  | 13,64%        | 61,84%        | 6,06%         | 36,16%        |
| Tương quan và hồi quy thống kê   | 10,00%        | 25,00%        | 0,00%         | 17,50%        |
| <b>Trung bình</b>                | <b>36,67%</b> | <b>72,46%</b> | <b>10,00%</b> | <b>54,20%</b> |

Từ Bảng 3.2 có thể thấy sau tinh chỉnh, độ chính xác của cả hai mô hình đều tăng ở tất cả các nhóm chủ đề. Tuy nhiên, mức cải thiện không đồng đều giữa các nhóm, cho thấy độ khó của từng dạng bài vẫn ảnh hưởng rõ rệt đến hiệu năng mô hình.

### Nhận xét kết quả thực nghiệm

Trước hết, Qwen2.5-Math là mô hình cho kết quả tốt hơn trên toàn bộ các nhóm chủ đề sau khi fine-tuning. Điều này cho thấy lợi thế của một mô hình có định hướng toán học ngay từ giai đoạn tiền huấn luyện, đặc biệt trong các bài toán yêu cầu suy luận nhiều bước và thao tác tính toán chính xác. Hai nhóm mà mô hình đạt kết quả nổi bật nhất là *Tính xác suất của biến cố* và *Quy luật phân phối xác suất*, với độ chính xác lần lượt đạt 95,00% và 89,86%.

Bên cạnh đó, Gemma-7B-it tuy có độ chính xác tuyệt đối thấp hơn, nhưng mức cải thiện sau tinh chỉnh lại khá rõ rệt. Từ mức ban đầu 10,00%, mô hình tăng lên 54,20%, cho thấy một mô hình tổng quát vẫn có thể thích nghi tương

đôi tốt khi được huấn luyện trên dữ liệu chuyên biệt và được tổ chức theo cấu trúc lời giải rõ ràng. Kết quả này cũng gợi ý rằng chất lượng dữ liệu và cách thiết kế đầu ra có ảnh hưởng đáng kể đến khả năng học của mô hình.

Ngược lại, nhóm bài toán về *tương quan và hồi quy* là nhóm khó nhất đối với cả hai mô hình. Sau tinh chỉnh, độ chính xác của Qwen2.5-Math và Gemma-7B-it ở nhóm này chỉ đạt lần lượt 25,00% và 17,50%. Điều đó cho thấy các bài toán dạng này vẫn là thách thức lớn, do thường yêu cầu kết hợp nhiều bước xử lý số liệu, đọc hiểu bảng dữ liệu và thiết lập mối quan hệ giữa các biến.

Nhìn chung, kết quả thực nghiệm cho thấy fine-tuning trên dữ liệu Xác suất – Thống kê bằng tiếng Việt đem lại hiệu quả rõ rệt cho cả hai mô hình. Trong đó, Qwen2.5-Math thể hiện ưu thế về độ chính xác, còn Gemma-7B-it cho thấy khả năng cải thiện mạnh sau tinh chỉnh. Điều này cho thấy cả kiến thức nền của mô hình lẫn chất lượng dữ liệu huấn luyện đều có vai trò quan trọng trong bài toán giải toán tự động.

### 3.2.3. Đánh giá chất lượng suy luận bằng LLM-as-a-Judge

Do Qwen2.5-Math sau tinh chỉnh là mô hình đạt kết quả tốt nhất trên tập kiểm tra, nghiên cứu tiếp tục đánh giá sâu hơn chất lượng lời giải của mô hình này bằng phương pháp *LLM-as-a-Judge*. Thay vì chỉ xem xét đáp án cuối, cách đánh giá này cho phép phân tích thêm về tính logic và độ chính xác trong quá trình lập luận. Kết quả chấm điểm theo từng nhóm chủ đề được trình bày tại Bảng 3.3

Bảng 3. 3. Điểm đánh giá LLM Judge theo từng nhóm chủ đề

| Nhóm mẫu                                           | Logic Score | Math Score | Overall |
|----------------------------------------------------|-------------|------------|---------|
| Chủ đề 1: Tính xác suất của biến cố                | 9.91        | 9.83       | 9.87    |
| Chủ đề 2: Biến ngẫu nhiên và các đặc trưng         | 8.53        | 7.85       | 8.19    |
| Chủ đề 3: Quy luật phân phối xác suất thông dụng   | 7.62        | 9.20       | 7.48    |
| Chủ đề 4: Bài toán ước lượng và kiểm định thống kê | 8.18        | 6.78       | 7.48    |



|                                                                 |      |      |      |
|-----------------------------------------------------------------|------|------|------|
| Chủ đề 5: Phân tích tương quan và hồi quy trong thống kê 2 biến | 5.00 | 3.15 | 4.08 |
|-----------------------------------------------------------------|------|------|------|

Kết quả cho thấy mô hình đạt chất lượng lời giải tốt nhất ở *Chủ đề 1: Tính xác suất của biến cố*, với điểm Logic Score và Math Score đều rất cao. Điều này cho thấy đây là nhóm bài mà mô hình không chỉ cho đáp án đúng với tỷ lệ cao mà còn duy trì được chuỗi suy luận hợp lý và phép tính chính xác.

Ở các nhóm *Biến ngẫu nhiên và các đặc trưng*, *Quy luật phân phối xác suất thông dụng* và *Ước lượng – kiểm định thống kê*, điểm số của mô hình nhìn chung ở mức khá, nhưng chưa thật sự đồng đều giữa khía cạnh suy luận và tính toán. Điều đó cho thấy mô hình đã có khả năng nhận diện dạng bài và triển khai lời giải tương đối hợp lý, tuy nhiên độ ổn định chưa cao ở mọi bước xử lý.

Nhóm *Phân tích tương quan và hồi quy trong thống kê 2 biến* tiếp tục là nhóm có kết quả thấp nhất, với Logic Score = 5.00, Math Score = 3.15 và Overall = 4.08. Kết quả này phù hợp với phân tích ở phần độ chính xác, đồng thời cho thấy đây không chỉ là nhóm khó về đáp án cuối mà còn là nhóm mà mô hình gặp khó khăn trong cả lập luận lẫn tính toán.

Nhìn chung, đánh giá bằng LLM Judge bổ sung thêm một góc nhìn quan trọng cho kết quả thực nghiệm. Nếu độ chính xác cho biết mô hình trả lời đúng đến đâu, thì điểm LLM Judge cho thấy chất lượng của lời giải do mô hình sinh ra. Kết hợp hai cách đánh giá này giúp việc phân tích mô hình trở nên toàn diện hơn.

### 3.3. PHÂN TÍCH SO SÁNH HIỆU SUẤT

#### 3.3.1. So sánh độ chính xác và chất lượng lời giải

##### 3.3.1.1. Về độ chính xác

Từ các kết quả trên có thể thấy Qwen2.5-Math là mô hình cho độ chính xác cao hơn trên toàn bộ các nhóm chủ đề. Đây là dấu hiệu cho thấy lợi thế của một mô hình có định hướng toán học trong giai đoạn tiền huấn luyện, nhất là khi áp dụng vào bài toán đòi hỏi suy luận và tính toán nhiều bước như Xác suất – Thống kê. Khi tiếp tục được fine-tune trên dữ liệu tiếng Việt, mô hình này duy trì được kết quả tốt và ổn định hơn trên tập kiểm tra.

Tuy vậy, nếu xét theo biên độ cải thiện sau tinh chỉnh thì Gemma-7B-it lại cho thấy mức thay đổi lớn hơn. Cụ thể, độ chính xác của Gemma-7B-it tăng thêm 44,20 %, trong khi Qwen2.5-Math tăng 35,79 %. Điều này cho thấy mặc

dù điểm xuất phát ban đầu thấp hơn, Gemma-7B-it vẫn có khả năng thích nghi khá tốt khi được huấn luyện trên dữ liệu có cấu trúc rõ ràng và phù hợp với tác vụ.

### 3.3.1.2. Về chất lượng lời giải

Nếu xét trên phương diện chất lượng chuỗi suy luận, Qwen2.5-Math thể hiện ưu thế rõ hơn ở các bài toán yêu cầu lập luận nhiều bước. Lời giải của mô hình thường có trình tự hợp lý, bám sát dữ kiện và ít xuất hiện lỗi logic trong quá trình biến đổi công thức. Khả năng xử lý ký hiệu toán học và biểu thức LaTeX của mô hình cũng tốt hơn, góp phần làm cho lời giải chặt chẽ và nhất quán hơn.

Trong khi đó, Gemma-7B-it có thể mạnh ở cách diễn đạt bằng tiếng Việt tự nhiên, mạch lạc và dễ tiếp cận hơn đối với người đọc. Đây là một ưu điểm đáng chú ý trong bối cảnh ứng dụng giáo dục, khi lời giải không chỉ cần đúng mà còn cần dễ hiểu đối với người học. Tuy nhiên, với những bài toán có chuỗi tính toán dài hoặc nhiều bước trung gian, mô hình vẫn dễ phát sinh sai sót số học. Vì vậy, Gemma-7B-it phù hợp hơn ở vai trò hỗ trợ giải thích, còn Qwen2.5-Math phù hợp hơn với các bài toán yêu cầu độ chính xác và tính chặt chẽ cao hơn trong lập luận.

### 3.3.2. So sánh tài nguyên tính toán

Nhờ áp dụng kỹ thuật lượng tử hóa 4-bit NF4 trong QLoRA, cả hai mô hình đều có thể được huấn luyện và suy luận trên cùng một loại phần cứng là GPU NVIDIA T4 16GB.

Điều này cho thấy phương pháp QLoRA đã giúp giảm đáng kể yêu cầu về bộ nhớ, từ đó làm cho việc fine-tuning các mô hình ngôn ngữ lớn trở nên khả thi ngay cả trong điều kiện tài nguyên tính toán không quá cao.

Mặc dù cùng được triển khai trên một môi trường phần cứng, hai mô hình vẫn có sự khác biệt nhất định về chi phí tính toán. Kết quả thực nghiệm cho thấy Gemma-7B-it có thời gian huấn luyện ngắn hơn và tốc độ sinh đầu ra nhanh hơn so với Qwen2.5-Math-7B. Cụ thể, Gemma-7B-it cần khoảng 3 giờ 30 phút cho mỗi epoch, trong khi Qwen2.5-Math-7B cần khoảng 4 giờ cho mỗi epoch. Ở giai đoạn suy luận, Gemma-7B-it đạt tốc độ khoảng 335 token/phút, cao hơn so với Qwen2.5-Math-7B ở mức 300 token/phút.

Sự chênh lệch này cho thấy Qwen2.5-Math-7B tiêu tốn nhiều thời gian xử lý hơn, đổi lại mô hình này có lợi thế về khả năng suy luận toán học và chất lượng lời giải trên tập kiểm tra. Ngược lại, Gemma-7B-it có ưu điểm về tốc độ

và hiệu quả tài nguyên, phù hợp hơn trong các tình huống cần triển khai nhanh hoặc yêu cầu phản hồi thời gian thực.

Bảng 3. 4. So sánh tài nguyên tính toán giữa hai mô hình

| Chỉ số                           | Gemma-7B-it    | Qwen2.5-Math-7B |
|----------------------------------|----------------|-----------------|
| Thời gian huấn luyện (giờ/epoch) | 3h30'          | 4h00'           |
| Tốc độ inference (token/phút)    | 335            | 300             |
| GPU sử dụng                      | NVIDIA T4 16GB | NVIDIA T4 16GB  |

Từ kết quả trên, có thể thấy tồn tại sự đánh đổi giữa hiệu quả tính toán và chất lượng chuyên môn của mô hình. Nếu mục tiêu là đạt độ chính xác cao hơn trên các bài toán Xác suất – Thống kê, đặc biệt là các bài toán yêu cầu suy luận toán học nhiều bước, thì Qwen2.5-Math-7B là lựa chọn phù hợp hơn. Ngược lại, nếu ưu tiên tốc độ huấn luyện, tốc độ suy luận và khả năng triển khai trên hạ tầng giới hạn, thì Gemma-7B-it là phương án cân bằng và hiệu quả hơn.

Nhìn chung, QLoRA đã góp phần thu hẹp đáng kể khoảng cách giữa yêu cầu phần cứng và khả năng triển khai thực tế. Nhờ đó, cả hai mô hình đều có thể được áp dụng trên GPU phổ thông với chi phí vận hành tương đối thấp, tạo điều kiện thuận lợi cho việc mở rộng ứng dụng trong các môi trường giáo dục có ngân sách hạn chế.

## CHƯƠNG 4: ĐÁNH GIÁ CHUYÊN SÂU VÀ CHIẾN LƯỢC CẢI TIẾN

Chương này đánh giá khách quan những thành tựu đạt được cũng như các hạn chế của giải pháp đề xuất. Dựa trên các phân tích đó, nghiên cứu đề xuất các định hướng cải tiến kỹ thuật trong tương lai và thảo luận về các khía cạnh đạo đức, pháp lý khi ứng dụng AI vào môi trường học thuật.

### 4.1. ĐÁNH GIÁ TOÀN DIỆN KẾT QUẢ

#### 4.1.1. Ưu điểm của mô hình

Qua quá trình triển khai và phân tích kết quả thực nghiệm, giải pháp tinh chỉnh LLM cho bài toán XSTK tiếng Việt thể hiện ba ưu điểm nổi bật:

- **Hiệu quả tinh chỉnh vượt trội:** Sự kết hợp giữa SFT và định dạng dữ liệu CoT đã kích hoạt thành công năng lực tiềm ẩn của các kiến trúc mô hình. Kết quả thực nghiệm minh chứng qua sự bứt phá mạnh về độ chính xác của Qwen2.5-Math (+35,79%) và Gemma-7B-it (+44,20%) so với phiên bản gốc.

- **Tư duy logic mạch lạc và tính minh bạch (Explainability):** Hệ thống thể định dạng phân cấp khắt khe (/buoc1, /buoc2, /ketluan) buộc mô hình sinh ra lời giải có tính hệ thống cao, bám sát quá trình tư duy tuần tự của con người – đặc biệt có giá trị trong bối cảnh giáo dục, nơi mục tiêu là giúp sinh viên hiểu cách giải chứ không chỉ biết đáp án.

- **Tối ưu hóa chi phí và khả năng triển khai thực tiễn:** Kỹ thuật QLoRA 4-bit giải quyết triệt để rào cản phần cứng. Khả năng huấn luyện và vận hành các mô hình 7B ngay trên GPU phổ thông mở ra cơ hội triển khai diện rộng cho các cơ sở giáo dục với ngân sách hạn chế.

#### 4.1.2. Phân tích hạn chế và hiện tượng ảo giác

Mặc dù đạt được những bước tiến khả quan, hệ thống vẫn bộc lộ những điểm yếu cố hữu:

- **Ảo giác số học (Arithmetic Hallucination):** Đây là lỗi nghiêm trọng và phổ biến nhất, được minh chứng rõ qua kết quả LLM-as-a-Judge: Math Score của nhóm câu sai chỉ đạt 4,42 trong khi Logic Score vẫn duy trì ở mức khá (6,28). Bản chất kiến trúc Transformer – vốn là mô hình xác suất trên các token, không phải hệ thống tính toán xác định – khiến việc loại bỏ hoàn toàn lỗi số học là thách thức cấu trúc.

- **Sai số lũy kế (Cascading Errors):** Ở các bài toán hồi quy yêu cầu tính tổng bình phương hoặc hiệp phương sai từ bảng số liệu lớn, một sai lệch nhỏ ở

bước đầu sẽ lan truyền và khuếch đại qua các phép tính tiếp theo, dẫn đến kết quả cuối cùng sai lệch lớn.

- **Ảo giác lý thuyết (Fact-conflicting Hallucination):** Mô hình đôi khi nhớ nhầm hoặc tự tạo ra (fabricate) các điều kiện áp dụng định lý không tồn tại. Điển hình là việc sử dụng sai phân phối (dùng phân phối  $Z$  thay vì Student- $t$  khi  $n < 30$ ).

- **Mất ổn định định dạng (Formatting Instability):** Dù đã được ép tuân thủ cấu trúc CoT, đầu ra LLM thỉnh thoảng vẫn thiếu thẻ điều hướng hoặc sinh thêm các chuỗi văn bản thừa sau khi đã đưa ra kết luận.

#### 4.2. ĐỀ XUẤT CHIẾN LƯỢC CẢI TIẾN

Nhằm khắc phục các hạn chế đã được chẩn đoán, nghiên cứu đề xuất năm chiến lược kỹ thuật trọng tâm:

- **Tích hợp công cụ tính toán ngoại vi (Tool-Augmented LLMs):** Đây là chiến lược cốt lõi và hiệu quả nhất để loại bỏ ảo giác số học. Thay vì ép LLM “tính nhầm”, hệ thống cần được tái cấu trúc để LLM đóng vai trò là một Tác tử (Agent) tự động gọi Python/Calculator cho các phép tính số học.

- **Tăng cường dữ liệu đa phương thức:** Mở rộng và cân bằng lại bộ dữ liệu, bổ sung lượng lớn các mẫu chứa cấu trúc bảng biểu định dạng Markdown hoặc CSV để giải quyết điểm nghẽn ở nhóm bài “Tương quan và hồi quy”.

- **Tối ưu hóa bằng phản hồi trực tiếp (DPO – Direct Preference Optimization):** Sau giai đoạn SFT, áp dụng thuật toán DPO để tinh chỉnh thêm bằng cách cung cấp cho mô hình các cặp lời giải tương phản. Cơ chế học sở thích (preference learning) sẽ giúp mô hình tự học cách “phạt” các chuỗi tư duy sai lệch.

- **Ứng dụng RAG (Retrieval-Augmented Generation):** Xây dựng cơ sở dữ liệu vector lưu trữ nội dung giáo trình XSTK chuẩn mực, đóng vai trò như một mỏ neo lý thuyết để ngăn mô hình tự bịa đặt công thức toán học.

- **Cải thiện kiểm soát định dạng đầu ra (Constrained Decoding):** Áp dụng các kỹ thuật ràng buộc cứng (hard constraints) trực tiếp lên quá trình sinh token, đảm bảo đầu ra luôn có đầy đủ các thẻ cấu trúc bắt buộc.

#### 4.3. ĐẠO ĐỨC VÀ PHÁP LÝ TRONG ỨNG DỤNG AI HỌC THUẬT

Việc triển khai AI tạo sinh vào môi trường giáo dục đại học đang đặt ra những thách thức sâu sắc về đạo đức và pháp lý, trước hết là vấn đề bản quyền

và bảo mật dữ liệu huấn luyện. Do bộ ngữ liệu tinh chỉnh được tổng hợp trực tiếp từ hệ thống đề thi và giáo trình do giảng viên cung cấp, các cơ sở giáo dục cần đảm bảo mọi hoạt động khai thác dữ liệu đều diễn ra hợp pháp. Quá trình này đòi hỏi sự đồng thuận rõ ràng từ tác giả gốc và sự tuân thủ nghiêm ngặt các quy định về sở hữu trí tuệ.

Bên cạnh đó, tính minh bạch học thuật (Academic Integrity) cũng là một khía cạnh cần đặc biệt lưu tâm. Việc ứng dụng một công cụ giải toán tự động có độ chính xác cao mang theo rủi ro sinh viên lạm dụng hệ thống để hoàn thành bài tập một cách thụ động, từ đó làm suy giảm năng lực tư duy độc lập. Để khắc phục, các trường đại học cần ban hành bộ quy tắc ứng xử rõ ràng, định vị hệ thống AI chỉ đóng vai trò là một “Trợ giảng ảo” (AI Tutor) nhằm hỗ trợ định hướng quá trình học tập, tuyệt đối không thay thế tư duy của người học. Đi kèm với đó là yêu cầu khắt khe về trách nhiệm giải trình (Accountability). Vì bản chất của các mô hình ngôn ngữ lớn (LLM) chưa thể loại bỏ hoàn toàn hiện tượng ảo giác (hallucination), người dùng cuối phải là cá nhân chịu trách nhiệm cao nhất đối với tính chính xác của thông tin khi áp dụng vào thực tiễn. Do vậy, hệ thống bắt buộc phải được tích hợp cơ chế cảnh báo tự động (Disclaimer) đính kèm tại mỗi kết quả đầu ra.

Cuối cùng, để giải quyết bài toán về tự chủ công nghệ và chủ quyền dữ liệu, hướng đi triển khai hệ thống AI cục bộ (On-premise) là một giải pháp tối ưu. Nghiên cứu đã minh chứng thành công tính khả thi của việc triển khai cục bộ thông qua các mô hình cỡ trung (như mốc 7 tỷ tham số). Cách tiếp cận này cho phép các trường đại học làm chủ hoàn toàn công nghệ lõi, đồng thời bảo vệ tuyệt đối quyền riêng tư đối với kho dữ liệu học thuật cũng như thông tin cá nhân của sinh viên.

## KẾT LUẬN

Khóa luận này đã triển khai nghiên cứu toàn diện về việc ứng dụng và tinh chỉnh các Mô hình ngôn ngữ lớn mã nguồn mở để tự động hóa giải bài tập Xác suất – Thống kê bằng tiếng Việt – một hướng nghiên cứu còn nhiều khoảng trống trong bối cảnh AI giáo dục tại Việt Nam. Thông qua quy trình kỹ thuật khép kín từ Data Engineering, Supervised Fine-Tuning bằng QLoRA đến hệ thống đánh giá LLM-as-a-Judge, nghiên cứu đã hoàn thành cả bốn mục tiêu đề ra và rút ra những kết luận khoa học quan trọng sau.

### 1. Kết quả đạt được

**Về xây dựng dữ liệu:** Nghiên cứu xây dựng thành công bộ dữ liệu 5.360 mẫu bài toán XSTK cấp đại học, được tổ chức theo cấu trúc Chain-of-Thought với hệ thống thẻ phân cấp chặt chẽ (/buoc1, /buoc2, /ketluan). Đây là đóng góp có giá trị thực tiễn cao cho cộng đồng NLP Việt Nam.

**Về tinh chỉnh mô hình:** Kỹ thuật QLoRA đã được triển khai thành công trên Gemma-7B-it (mô hình đa dụng) và Qwen2.5-Math-7B (mô hình chuyên biệt toán học) hoàn toàn trong giới hạn GPU phổ thông NVIDIA T4 (16GB VRAM). Kết quả ghi nhận cải thiện vượt bậc: Qwen2.5-Math tăng từ 36,67% lên 72,46% (+35,79 pp) và Gemma-7B-it tăng từ 10,00% lên 54,20% (+44,20 pp).

**Về khung đánh giá:** Hệ thống LLM-as-a-Judge hai lớp vượt qua giới hạn của các độ đo  $n$ -gram, cho phép đánh giá đồng thời tính đúng đắn toán học, chất lượng lập luận logic và chuẩn mực định dạng. Phân tích điểm số phân tầng (câu đúng: Overall 9,13; câu sai: Overall 5,35) phát hiện hiện tượng Arithmetic Hallucination quan trọng: mô hình chủ yếu thất bại ở bước tính toán số học cuối cùng (Math Score: 4,42) chứ không phải ở bước thiết lập logic giải (Logic Score: 6,28).

**Về phân tích đối sánh:** Nghiên cứu cung cấp bằng chứng thực nghiệm rõ ràng về sự phân hóa giữa hai kiến trúc: Qwen2.5-Math vượt trội về độ chính xác tuyệt đối và tính chặt chẽ chuỗi suy luận toán học; Gemma-7B-it có lợi thế về diễn đạt tiếng Việt tự nhiên và tiêu thụ tài nguyên tính toán thấp hơn.

### 2. Hạn chế còn tồn tại

Mặc dù đạt kết quả khả quan, hệ thống vẫn còn những điểm yếu cần thừa nhận khách quan. Hiện tượng ảo giác số học chưa được loại bỏ hoàn toàn – đây là hạn chế mang tính cấu trúc, xuất phát từ bản chất token-prediction của kiến

trúc Transformer. Nhóm bài “Tương quan và hồi quy” đạt hiệu năng thấp nhất (Qwen FT: 25,00%; Gemma FT: 17,50%) do đặc thù dữ liệu bảng biểu đầu vào hai chiều.

### **3. Ý nghĩa chiến lược**

Nghiên cứu minh chứng tính khả thi của triển khai AI cục bộ (On-premise) trong giáo dục đại học tại Việt Nam. Hướng tiếp cận này cho phép các cơ sở đào tạo làm chủ hoàn toàn công nghệ lõi, bảo đảm an toàn dữ liệu học thuật và tối ưu chi phí vận hành dài hạn.

### **4. Hướng phát triển tiếp theo**

Dựa trên các hạn chế đã được chẩn đoán, em nghiên cứu đề xuất ba hướng ưu tiên cho các công trình tiếp theo. Thứ nhất và quan trọng nhất là tích hợp công cụ tính toán ngoại vi (Tool-Augmented LLMs): tái cấu trúc hệ thống để LLM đóng vai trò Tác tử tự động gọi Python/Calculator cho các phép tính số học, từ đó loại bỏ hoàn toàn ảo giác số học. Thứ hai là mở rộng và cân bằng lại bộ dữ liệu, đặc biệt bổ sung các mẫu có cấu trúc bảng Markdown/CSV cho nhóm bài hồi quy. Thứ ba là áp dụng thuật toán DPO sau giai đoạn SFT để tinh chỉnh thêm chất lượng chuỗi suy luận thông qua cơ chế học có phần thưởng.

Tóm lại, khóa luận này đã đóng góp một bước tiến có ý nghĩa trong ứng dụng Trí tuệ nhân tạo vào giáo dục toán học bậc đại học tại Việt Nam, đồng thời đặt nền móng kỹ thuật vững chắc cho các nghiên cứu chuyên sâu hơn về AI Tutor thông minh, minh bạch và hoạt động tự chủ hoàn toàn trong môi trường giáo dục Việt Nam.



## TÀI LIỆU THAM KHẢO

1. Trương Hana (2023), “ChatGPT và giáo dục: Tổng quan tình hình nghiên cứu trên thế giới và Việt Nam”, *ResearchGate*.
2. Khang Doan (2024), *Vietnamese-LLM-instruction-datasets*, GitHub.
3. Pham Van Khanh, Pham Vu Anh Tuan (2025), “Building a Vietnamese Math Chatbot based on RAG and LLM: System design, implementation and experimental evaluation”, *HNUE Journal of Science*.
4. Nguyễn Đăng Khoa, Nguyễn Quốc Hưng (2024), “Phát triển ứng dụng AI trong giáo dục đại học tại Việt Nam: Cơ hội, thách thức và giải pháp”, *Trường Đại học Kinh tế Quốc dân*.
5. Nguyễn Thị Ngọc (2024), “Toàn cảnh AI trong giáo dục”, *FPT IS*.
6. Dao Xuan-Quy, Le Ngoc-Bich, Vo The-Duy và cs. (2023), “Mathematical Capabilities of Large Language Models on Vietnamese High School Math Test (VNHSGE)”, *Eastern International University Scientific Conference*.
7. DeepSeek-AI (2025), *DeepSeek-RL: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*, arXiv:2501.12948.
8. Dettmers T., Pagnoni A., Holtzman A., Zettlemoyer L. (2023), *QLoRA: Efficient Finetuning of Quantized LLMs*, arXiv:2305.14314.
9. Google AI (2024), *Gemma 7B Model Card*, Hugging Face.
10. Google AI for Developers (2024), *Fine-Tune Gemma using Hugging Face Transformers and QLoRA*.
11. Hu E. J., Shen Y., Wallis P., Allen-Zhu Z., Li Y., Wang S., Wang L., Chen W. (2021), *LoRA: Low-Rank Adaptation of Large Language Models*, arXiv:2106.09685.
12. Hugging Face (2024), *Fine-tuning Gemma Models in Hugging Face*.
13. Hugging Face (2024), *Open RL*, GitHub.
14. Meta (2024), *Llama 3.1 8B Model Card*, Hugging Face.
15. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser L., Polosukhin I. (2017), *Attention Is All You Need*, arXiv:1706.03762.

16. Wang R., Wang R., Shen Y., Wu C., Zhou Q., Chandra R. (2025), *Evaluation of LLMs for Mathematical Problem Solving*, arXiv:2506.00309.